
MODULO 1

Classificazione fine-grained e fusione immagine-tabella



CHI VI PARLA

Giacomo Nunziati

- **Ingegnere informatico** con specializzazione in AI — Università di Siena.
- **PhD in Smart Computing** (intelligenza artificiale) — Università di Siena e Università di Firenze.

CONTATTI giacomo.nunziati.0@gmail.com



Obiettivi e struttura della lezione



Struttura del corso

- **Cinque lezioni, cinque casi applicativi.** Immagini, dati tabellari, serie temporali, video, audio.
- **Cinque step ricorrenti:** il problema, i dati, dalla baseline al metodo, la valutazione, la produzione.
- **Prerequisiti:** Python, PyTorch (base), train/validation/test, backpropagation, CNN e transfer learning, metriche di base.



STEP 1

Classificazione fine-grained e dati multimodali

Classificazione fine-grained: definizione

Un problema di classificazione è **fine-grained** quando ci sono gruppi di classi che appartengono a una stessa macro-categoria e si distinguono per differenze locali di piccola entità.

- specie di uccello all'interno dello stesso genere
- modelli di prodotto della stessa linea
- varianti dimensionali dello stesso componente

La conseguenza è che la varianza intra-classe supera la varianza inter-classe.

Caratteristiche del problema fine-grained

CLASSIFICAZIONE GENERICA

- categorie semanticamente distanti
- texture e colore globali sono sufficienti
- la posa e lo sfondo variano meno del contenuto
- l'accuracy cresce con la quantità di dati

FINE-GRAINED

- categorie vicine, spesso con la stessa struttura
- le feature discriminanti sono **poche, piccole e localizzate**
- posa, illuminazione e sfondo variano più della differenza fra le classi

Nelle immagini, il modello deve **localizzare la regione discriminante**, oltre a riconoscere la categoria.

Domini di applicazione

- riconoscimento di specie animali e vegetali
- controllo qualità su componenti simili fra loro
- identificazione di modelli e varianti di prodotto
- riconoscimento di volti, dominio in cui sono nate molte delle tecniche di oggi



Larus, gabbiano — riferimento




Larus, gabbiano — stessa specie



Sterna hirundo — specie diversa

Le tecniche presentate oggi provengono in larga parte dalla letteratura sul **riconoscimento facciale**, dove il numero di categorie è grande e le differenze sono piccole.

Dati multimodali: immagine e variabili tabellari



- **misure fisiche** rilevate da uno strumento: dimensioni, peso, conducibilità
- **parametri di processo**: lotto, macchina, tempo di lavorazione
- **condizioni di acquisizione**: distanza, illuminazione, sensore

La stessa architettura copre casi molto diversi. Cambia il significato del vettore, e da quello dipendono la presenza e l'entità del guadagno ottenuto con la fusione.

Quando una variabile tabellare è informativa

- **Criterio operativo:** una variabile tabellare è utile quando porta informazione che l'immagine non consente di ricostruire.
- Una misura in millimetri presa da uno strumento **soddisfa** il criterio: la fotografia non contiene la scala assoluta.
- Una misura in pixel ricavata dall'immagine stessa **non lo soddisfa**: dipende dalla distanza di ripresa e approssima ciò che la CNN già osserva.
- Una descrizione compilata da un annotatore che ha già riconosciuto l'oggetto costituisce **data leakage**.

È opportuno verificare l'informatività prima di costruire il modello.

Il caso in esame

20

categorie

1.187

immagini

599 / 588

train e test

- **CUB-200-2011**, sottoinsieme di venti classi: otto gabbiani, sette sterne, cinque martin pescatori. Tre generi completi.
- Gabbiani e sterne si confondono fra loro; i martin pescatori forniscono il contrasto che rende leggibile la matrice di confusione.
- Ogni immagine porta **quindici coordinate di parti annotate**, un **bounding box** e **312 attributi** visivi.
- Dalle coordinate e dal box si costruisce un vettore di misure geometriche, che è la componente tabellare del problema.


CUB-200-2011, Wah et al., Caltech 2011. Il dataset non ha una licenza standard e i suoi termini limitano l'uso a ricerca e didattica non commerciali.




STEP 1.5

Che cosa rende il problema difficile

Separabilità delle classi



cross-entropy




loss a margine

- La cross-entropy ottimizza la **correttezza della classificazione**, e si ferma appena il decision boundary separa i dati di training.
- Non impone alcuna distanza minima fra le classi, né compattezza all'interno della classe.
- Con classi vicine, il margine risultante è sottile e il modello generalizza male su esempi che cadono vicino al confine.

Una possibile direzione, prima di intervenire sull'architettura del modello e sui dati, è cambiare la **funzione obiettivo**.

Distribuzione a coda lunga



- In molti dataset reali, la frequenza delle categorie segue tipicamente una legge di potenza.
- La accuracy complessiva è dominata dalle categorie frequenti e **non riflette** il comportamento sulla coda.
- Le categorie rare sono spesso quelle il cui errore costa di più.

Selezionare le metriche più indicative (come la **macro-average della recall**, affiancata alla recall per classe) diventa cruciale.



Insiemi di classi aperti


CLOSED SET

- l'insieme delle categorie è fissato all'addestramento
- ogni input riceve una delle categorie note
- un oggetto fuori catalogo viene assegnato comunque

OPEN SET

- il modello può restituire «categoria sconosciuta»
- serve un criterio di rifiuto e una soglia
- la valutazione deve misurare anche ciò che il modello non risponde

Costo dell'errore non uniforme



- Le metriche standard trattano ogni errore allo stesso modo.
- In un dominio con gerarchia esplicita, confondere due categorie vicine può avere conseguenze diverse rispetto a confondere due categorie distanti.
- Se la gerarchia è nota a priori, è utilizzabile sia nella valutazione sia nella loss.

Dopo aver individuato una metrica, è utile stabilire a priori quale errore è accettabile e quale no.

Rumore di annotazione

- **Etichette errate.** Su dataset raccolti da fonti eterogenee la quota di etichette sbagliate è tipicamente di alcuni punti percentuali.
- **Etichette ambigue.** Categorie definite in modo non disgiunto, o casi di confine su cui due annotatori non concordano.
- **Classi con più aspetti visivi.** Una stessa categoria fotografata in configurazioni diverse produce cluster distinti nello spazio delle feature.
- Una loss che impone compattezza intra-classe (spesso usate in classificazione fine-grained) **amplifica** l'effetto del rumore: può forzare anche esempi eterogenei verso un unico centro.

Criticità specifiche della fusione multimodale

- **Squilibrio dimensionale.** Un embedding visivo ha ordine 10^3 componenti, un vettore tabellare ordine 10^4 . Senza bilanciamento, il contributo del secondo può essere marginale.
- **Velocità di overfitting diverse.** Le due modalità raggiungono l'overfitting in momenti diversi; un'unica strategia di addestramento è subottimale per almeno una delle due.
- **Leakage asimmetrico.** Il ramo tabellare è il punto in cui una variabile derivata dal target entra più facilmente.
- **Modalità mancanti.** È necessario definire il comportamento del modello in caso di modalità mancanti.

Wang, Tran e Feiszli (CVPR 2020) documentano che la migliore rete a modalità singola supera quella multimodale in modo consistente su più benchmark. Un risultato negativo della fusione rientra fra gli esiti attesi, se non si applicano contromisure per ognuna delle criticità.



STEP 2

Costruzione e preprocessing dei dati

Composizione del vettore tabellare

TIPO DI VARIABILE	ESEMPI	TRATTAMENTO
continua, misurata	dimensioni, peso, temperatura	standardizzazione
continua, derivata	rapporti, aree, indici	verifica di indipendenza dall'etichetta
categorica a bassa cardinalità	tipo di sensore, turno	one-hot encoding
categorica ad alta cardinalità	codice lotto, operatore	embedding appreso
conteggio	numero di difetti rilevati	trasformazione logaritmica

Le variabili derivate richiedono una verifica esplicita: la formula che le costruisce può contenere il target senza che sia evidente.

Data leakage

- **Definizione.** Una variabile disponibile in addestramento che in produzione non esiste, o che contiene informazione sull'etichetta ottenuta a valle del fenomeno da predire.
- **Segnale diagnostico.** Un modello semplice sulla sola variabile sospetta raggiunge una accuracy anomala, spesso prossima al valore massimo.
- **Forma frequente nel fine-grained:** attributi descrittivi compilati da un annotatore che ha già riconosciuto la categoria.
- **Forma frequente nell'industria:** un identificativo di lotto o di macchina correlato al prodotto, un timestamp che ordina implicitamente le categorie.

È opportuno eseguire il controllo prima dell'addestramento, su ogni colonna, e va ripetuto ogni volta che la sorgente dei dati cambia.

Misure strumentali e annotazioni umane

MISURA STRUMENTALE

- prodotta da uno strumento, in unità fisiche
- indipendente dal riconoscimento della categoria
- riproducibile e soggetta a errore quantificabile
- disponibile in produzione con lo stesso protocollo

ANNOTAZIONE UMANA

- prodotta da un osservatore
- **posteriore** al riconoscimento della categoria
- variabile fra annotatori
- raramente disponibile in produzione

Le due tipologie possono coesistere nello stesso vettore tabellare, ma sono da trattare in modi differenti. La seconda va trattata come una possibile fonte di leakage.



Preprocessing delle variabili tabellari

- **Statistiche dal solo training set.** Media, deviazione standard e mediane di imputazione si calcolano sul training set e si applicano invariate a validation e test.
- **Imputazione dei valori mancanti.** Mediana per le continue (un indicatore binario di «valore mancante» conserva l'informazione). Categoria dedicata per le categoriche.
- **Variabili con quota di mancanti elevata.** Sopra una certa soglia conviene escluderle: una variabile assente in un terzo dei casi può introdurre più rumore rispetto al guadagno di informazione.
- **Proiezione.** Prima della fusione i due vettori da fondere devono essere portati a una dimensionalità confrontabile.

Data augmentation e dominio di acquisizione

Di seguito alcuni esempi di tecniche di augmentation. La categorizzazione "APPLICABILE" o "NON APPLICABILE" vale per un dominio ad **acquisizione controllata**: piano fisso, illuminazione calibrata, un oggetto per scatto.

flip orizzontale

APPLICABILE

se l'orientamento dell'oggetto sul piano può variare

random crop

APPLICABILE

se la localizzazione a monte è imprecisa

rotazione limitata

APPLICABILE

l'orientazione può variare

color jitter

NON APPLICABILE

se sensore e illuminazione costanti

distorsione prospettica

NON APPLICABILE

se la camera è in posizione fissa

rumore gaussiano forte

NON APPLICABILE

se il sensore è noto e stabile

Ogni trasformazione va giustificata da una variazione che esiste nel dominio di produzione. Trasformazioni improbabili possono danneggiare le capacità del modello (che deve apprendere un task più complesso, senza che rispecchi il task reale).



STEP 3

Dalla baseline alle soluzioni avanzate

Baseline: transfer learning e classification head softmax



MODALITÀ	COSA SI AGGIORNA	QUANDO
feature extraction	solo la testa	pochi dati, dominio vicino o incluso in quello di pre-training
fine-tuning parziale	ultimi blocchi e testa	caso più frequente
fine-tuning completo	tutta la rete	molti dati, dominio distante


Il learning rate del backbone e quello della testa sono tipicamente parametri distinti. Un valore unico degrada le feature pre-addestrate nelle prime epoche, in particolare in presenza di dataset limitati.

Limiti della softmax head nella classificazione fine-grained


- La cross-entropy raggiunge il minimo quando ogni esempio di training è classificato correttamente. **La geometria dello spazio delle feature non è considerata nell'obiettivo.**
- La conseguenza si vede sugli esempi di test prossimi al confine, che nel fine-grained sono la maggioranza (probabilità che due esempi appartengano a classi diverse è più alta).
- Il **label smoothing** riduce la sovrastima della confidenza e migliora la calibrazione, senza intervenire sulla geometria.

Per ottenere separazione servono due modifiche: normalizzare, così che la decisione dipenda da un angolo, e imporre un margine su quell'angolo.

Normalizzazione di embedding e pesi



prima: la norma varia



dopo: solo la direzione conta

- Normalizzando l'embedding e i vettori di classe, il prodotto scalare coincide con il **coseno dell'angolo** fra i due.
- Il logit perde la dipendenza dalla norma e dipende solo dalla direzione.

Su una rappresentazione angolare, imporre una distanza minima fra le classi diventa un'operazione ben definita.

Che cos'è un vettore di classe

La matrice dei pesi **W** ha **una riga per classe**. Dopo la normalizzazione ogni riga è un vettore unitario, cioè un **punto sull'ipersfera**.

- Quel vettore è la classe: è la direzione verso cui gli embedding di quella classe vengono spinti.
- Il logit della classe i è il coseno dell'angolo fra l'embedding e la riga w_i .

W NORMALIZZATA — UNA RIGA PER CLASSE

w_1								$\ w\ = 1$
w_2								$\ w\ = 1$
w_3								$\ w\ = 1$
w_N								$\ w\ = 1$

«Vettore di classe», «centro» e «prototipo», in questo contesto, sono **la stessa cosa**.

Margine angolare

Il margine si somma all'angolo della sola classe corretta durante l'addestramento. In inferenza il margine non si applica.

arcface.py

```
cos      = F.linear(F.normalize(x), F.normalize(W))    # il logit e' un coseno
theta    = cos.acos() + one_hot(y) * MARGIN           # solo la classe corretta
logits   = SCALE * theta.cos()
```

L'effetto è chiedere al modello una separazione superiore a quella necessaria per classificare, e ottenere così **compattezza intra-classe** e **distanza inter-classe**.

SphereFace, CosFace, ArcFace

METODO	DOVE AGISCE IL MARGINE	FORMA DEL LOGIT
SphereFace	moltiplica l'angolo	$\cos(m \cdot \theta)$
CosFace	si sottrae al coseno, adimensionale	$\cos(\theta) - m$
ArcFace	si somma all'angolo, in radianti	$\cos(\theta + m)$

I tre parametri appartengono a scale diverse e **non sono intercambiabili**. Un margine ArcFace di 0.5 corrisponde a 28,6 gradi; il valore tipico di CosFace è 0.35 sul coseno.

SphereFace richiede accorgimenti di addestramento per convergere; ArcFace converge tipicamente senza loss ausiliarie.

Scelta di margine e scala

- **Intervallo esplorato in letteratura.** L'ablazione originale di ArcFace copre margini fra 0.40 e 0.55, con differenze di frazioni di punto. Fuori da quella finestra il comportamento cambia in modo netto.
- **Il punto di partenza dell'addestramento.** All'inizializzazione gli embedding sono quasi ortogonali ai vettori di classe: il logit della classe corretta vale $s \cdot \cos(90^\circ + m)$ e gli altri valgono circa zero. Più il margine è grande, più la loss iniziale è alta.
- **Il limite superiore dipende dal numero di classi.** CosFace deriva un limite per il margine che si stringe al crescere delle classi.
- **La scala moltiplica il costo del margine.** A margine nullo la scala non sposta il punto di partenza; a margine grande lo amplifica proporzionalmente.


I due parametri vanno tarati congiuntamente. Un addestramento che non converge ad alto margine si recupera spesso [abbassando la scala](#).

Varianti della loss a margine

- **AdaFace** — adatta il margine alla qualità stimata dell'immagine. Rilevante con acquisizione eterogenea, meno con acquisizione controllata.
- **ElasticFace** — margine campionato da una distribuzione invece che fisso, come regolarizzazione.
- **Scheduling sul margine** — si parte da un valore basso e lo si aumenta durante l'addestramento. Aggira il problema del punto di partenza ed è una tecnica molto usata su cataloghi grandi.
- **CurricularFace, MagFace** — riformulazioni successive, con guadagni contenuti sui benchmark standard.

Il margine programmato è l'unica di queste che risolve un problema pratico ricorrente, e ha un costo di implementazione trascurabile.

Sub-center ArcFace



- Ogni classe riceve **K sotto-centri**. Il logit della classe è il **massimo** delle similarità sui K centri, quindi un esempio deve avvicinarsi a uno qualsiasi di essi.
- Rilassa il vincolo di compattezza intra-classe. Il valore di riferimento nel paper originale è $K = 3$; oltre $K = 10$ i sotto-centri restano poco utilizzati e la capacità discriminante cala.

- **Su dati puliti $K > 1$ peggiora.** Compattezza e tolleranza alla varianza sono lo stesso parametro letto nei due versi.
- Il metodo nasce per il **rumore di etichetta**, e la procedura originale scarta i sotto-centri non dominanti a fine addestramento.

Il meccanismo non distingue un'etichetta errata da una classe con più aspetti visivi. Per il secondo uso i sotto-centri non dominanti vanno conservati, invertendo l'ultimo passo della procedura originale.

Separazione fra rappresentazione e classificatore



- Kang et al. (ICLR 2020) mostrano che il **campionamento per istanza**, cioè quello naturale e sbilanciato, produce la rappresentazione più generalizzabile.
- Il ribilanciamento va applicato **al solo classificatore**, dopo, con la rappresentazione congelata.
- Il costo è una frazione dell'addestramento completo, perché la rappresentazione non si ricalcola.

La conseguenza pratica: la scelta della classification head è separabile dall'addestramento della backbone e si può iterare su di essa più velocemente.

Quattro regole di decisione

Tutte sulla stessa rappresentazione congelata.

1 · TESTA LINEARE

Il classificatore addestrato insieme alla rappresentazione. Baseline di confronto.

2 · RIADDESTRAMENTO BILANCIATO

Si reinizializza la testa e la si addestra con campionamento bilanciato per classe. Due varianti a costo quasi nullo:

τ -normalization — i pesi appresi si dividono per $\|w_i\|^\tau$, con τ tarato su validation: sgonfia la norma delle classi frequenti, che la cross-entropy ha fatto crescere. Nessun addestramento.

Learnable weight scaling — si congelano le direzioni dei pesi e si apprende **un solo fattore di scala per classe**.

3 · PROTOTIPI

Media degli embedding per classe, normalizzata; si assegna alla classe più vicina in coseno. Una categoria nuova richiede il calcolo di un vettore.

4 · NEAREST NEIGHBOUR

Confronto con tutti gli embedding di training. Consente una soglia di rifiuto e non richiede alcun addestramento aggiuntivo.

Le quattro distribuiscono l'errore in modo diverso fra classi frequenti e rare. La scelta è una **decisione di prodotto**, non di ottimizzazione.

Classificazione vs retrieval

	CLASSIFICATORE CHIUSO	RETRIEVAL SU EMBEDDING
decisione	testa dimensionata su N classi	confronto con un indice
categoria nuova	riga di pesi, riaddestramento, rivalidazione	inserimento di un vettore
rifiuto	richiede una calibrazione a parte	nativo, tramite soglia
accuracy sulle categorie frequenti	tipicamente superiore	inferiore

Il criterio principale di scelta è il **costo di manutenzione** atteso, determinato dalla frequenza con cui il catalogo cambia.

Strategie di fusione



- **A · fusione precoce — concatenazione.** Il vettore tabellare proiettato viene affiancato all'embedding della CNN, e il bottleneck proietta il vettore congiunto.
- **B · dopo il bottleneck — concatenazione,** sulla rappresentazione che entra nella testa. È la forma più diffusa e la meno costosa.
- **C · FiLM — non è concatenazione.** Il vettore tabellare produce due numeri per canale, γ e β , e le feature map vengono trasformate come $\gamma \odot h + \beta$. La dimensione della rappresentazione non cambia: cambiano i valori.
- **D · livello di decisione — nessuna fusione di feature.** Due modelli separati, si combinano le uscite: immune allo squilibrio dimensionale, cieca alle interazioni fra le modalità.

MetaBlock (Pacheco e Krohling, IEEE JBHI 2021) applica la modulazione a metadati tabellari nel dominio medico e supera la concatenazione.

Interazione fra fusione e margine angolare

- Una loss a margine angolare opera su **embedding normalizzati**: la rappresentazione vive su un'ipersfera e la decisione dipende solo dalla direzione.
- Concatenare componenti numeriche e poi normalizzare significa che quelle componenti **occupano parte della norma unitaria**, sottraendola alle componenti visive.
- Se la variabile numerica è **quasi costante dentro la classe**, favorisce la compattezza intra-classe che il margine richiede.
- Se **varia molto dentro la classe**, agisce in direzione opposta al margine, e il caso ricade in quello dei sotto-centri.

La triste verità (o grande opportunità): la combinazione di loss a margine e fusione tabellare è poco documentata in letteratura. Le due famiglie di metodi sono studiate separatamente, e l'interazione va verificata sul proprio caso.



Metodi non trattati

METODO	RIFERIMENTO	FONTE
Bilinear CNN	Lin, RoyChowdhury, Maji — ICCV 2015	arXiv:1504.07889
Compact Bilinear Pooling	Gao, Beijbom, Zhang, Darrell — CVPR 2016	arXiv:1511.06062
RA-CNN, part-based ricorrente	Fu, Zheng, Mei — CVPR 2017	openaccess.thecvf.com
Destruction and Construction Learning	Chen, Bai, Zhang, Mei — CVPR 2019	openaccess.thecvf.com
TransFG, transformer per fine-grained	He et al. — AAAI 2022	arXiv:2103.07976
Triplet loss	Schroff, Kalenichenko, Philbin — CVPR 2015	arXiv:1503.03832
Contrastive loss	Hadsell, Chopra, LeCun — CVPR 2006	ieeexplore.ieee.org
Knowledge distillation	Hinton, Vinyals, Dean — 2015	arXiv:1503.02531
MixUp	Zhang et al. — ICLR 2018	arXiv:1710.09412
CutMix	Yun et al. — ICCV 2019	arXiv:1905.04899

I riferimenti sono link cliccabili nella versione HTML delle slide.



STEP 4

**Metriche,
protocollo e
interpretabilità**



Metriche di classificazione multiclasse

METRICA	COSA MISURA	QUANDO È FUORVIANTE
accuracy	frazione di predizioni corrette	classi sbilanciate
macro-average recall	media delle recall per classe	nasconde la varianza fra classi
recall per classe	comportamento su ciascuna categoria	poco leggibile con molte classi
precision per classe	affidabilità di ciascuna predizione	dipende dalla prevalenza

Con classi sbilanciate, accuracy e macro-average divergono. Vanno riportate entrambe, e la seconda è quella che descrive il comportamento sulla coda.

Errore gerarchico e top-k accuracy

ERRORE GERARCHICO


- si misura a quale livello della gerarchia l'errore si verifica
- distingue una confusione fra categorie vicine da una fra categorie distanti
- richiede una tassonomia dichiarata a priori

TOP-K ACCURACY

- misura se la categoria corretta è fra le prime k proposte
- pertinente quando il sistema è di supporto a un operatore umano
- non pertinente quando la decisione innesca flussi automatici a valle

Entrambe descrivono la **gravità** dell'errore invece della sola frequenza, ed entrambe richiedono di avere una conoscenza a priori del sistema e di come verrà usato.

Matrice di confusione



- Con molte categorie la matrice completa non è leggibile cella per cella.
- Ordinando le classi secondo la gerarchia del dominio, la struttura emerge **a blocchi**.
- I blocchi fuori diagonale indicano confusioni sistematiche fra gruppi, che hanno cause diverse dagli errori isolati.

La matrice serve a formulare ipotesi sulle cause dell'errore. Le metriche aggregate servono a decidere.

Significatività statistica di una differenza di performance

- La accuracy misurata su un test set finito è una **stima**, con un'incertezza che dipende dalla dimensione del test set.
- Su un test set di poche centinaia di esempi, l'intervallo di confidenza al 95% ha semiampiezza di alcuni punti percentuali.
- **La risoluzione della metrica è limitata:** con N esempi di test, una singola predizione vale $1/N$.

Prima di confrontare due modelli o protocolli di training va stabilito **quale differenza il test set consente di distinguere.**

Confronto fra due modelli: test di McNemar

	B CORRETTO	B ERRATO
A corretto	a — concordi corretti	b — solo A
A errato	c — solo B	d — concordi errati

Le accuracy dei due modelli differiscono di $(b - c) / n$: **solo b e c** le distinguono.

IPOTESI NULLA

H_0 : b e c hanno la stessa probabilità

STATISTICA (χ^2 , 1 G.D.L.)

$$\chi^2 = (|b - c| - 1)^2 / (b + c)$$

VERSIONE ESATTA

$$b \sim \text{Bin}(b + c , \frac{1}{2})$$

$$p = 2 \cdot P(X \geq \max(b, c))$$

- Il -1 è la correzione di continuità; con $b + c < 25$ si usa il test binomiale esatto.
- $p < 0,05$: lo scarto osservato non è spiegabile dal caso.

La significatività dipende dal **numero di discordanze $b + c$** : poche discordanze rendono rilevabile anche uno scarto piccolo, molte discordanze ne richiedono uno grande.

Criticità del protocollo sperimentale

- **Selezione sul test set.** Scegliere iperparametri guardando il test set trasforma la stima finale in una stima ottimistica. Serve un validation set separato.
- **Split stratificato.** Se più immagini provengono dallo stesso oggetto, dalla stessa sessione o dallo stesso lotto, devono cadere tutte dallo stesso lato dello split.
- **Confronti multipli.** Provare molte configurazioni e riportare la migliore introduce un bias di selezione proporzionale al numero di prove. Il test set è diventato solo un altro validation set.
- **Variabilità di inizializzazione.** Con effetti dell'ordine del punto percentuale, la differenza fra due seed può superare la differenza fra due metodi.

Un confronto va ripetuto su più seed e riportato con la sua dispersione. Un singolo valore non è confrontabile con un altro singolo valore.

Attribuzione del contributo per modalità

MODELLO ADDESTRATO	VALORE
nessuna modalità	$v(\emptyset)$ — riferimento casuale
solo immagine	$v(I)$
solo variabili tabellari	$v(T)$
entrambe	$v(I, T)$

- v è la metrica scelta (per esempio la macro-average recall) misurata su quel modello.
- Con due modalità i sottoinsiemi sono quattro: quattro addestramenti, e i valori di Shapley si ottengono **in forma chiusa**.

VALORE DI SHAPLEY DELLA MODALITÀ TABELLARE

$$\phi_T = \frac{1}{2} \cdot [v(T) - v(\emptyset)] + \frac{1}{2} \cdot [v(I, T) - v(I)]$$

Media fra il contributo **da sola** e il contributo **in aggiunta all'immagine**: i due ordini di ingresso pesano allo stesso modo.

$$\phi_I + \phi_T = v(I, T) - v(\emptyset)$$

L'intero guadagno sopra il riferimento è ripartito fra le due modalità: nessuna quota resta non attribuita.

- Shapley alto e **incremento marginale** $v(I, T) - v(I)$ vicino a zero → modalità **informativa ma ridondante**.

L'ablazione semplice, cioè azzerare una modalità, non distingue fra ridondanza e assenza di informazione. Con due modalità il calcolo completo ha un costo trascurabile.



STEP 5

Production e manutenzione

Detection a monte della classificazione



- L'accuracy del sistema è il **prodotto** delle accuracy dei singoli stadi. La media dei valori per stadio sovrastima il risultato end-to-end.
- Un errore di localizzazione produce un ritaglio fuori distribuzione, su cui il classificatore è tipicamente sovraconfidente.
- La valutazione end-to-end e quella per stadio danno risultati diversi. Entrambe servono, e per motivi diversi.
- Il classificatore va addestrato sui **ritagli prodotti dal detector reale**, non su ritagli ideali da annotazione manuale.

La distribuzione degli ingressi del secondo stadio dipende dal comportamento del primo, incluse le sue modalità di errore.



Drift e manutenzione del modello

- **Drift del dato.** Cambiano illuminazione, sensore, fornitore, aspetto del prodotto. La distribuzione degli ingressi si allontana da quella di addestramento.
- **Drift del catalogo.** Categorie nuove, categorie ritirate, categorie che si suddividono.
- **Ritaratura della soglia.** Precede il riaddestramento e ha un costo molto inferiore.

Best practice: progettare il protocollo di monitoraggio insieme al modello.

Preprocessing e riproducibilità

- **Il preprocessing fa parte del modello.** Ridimensionamento, ritaglio, normalizzazione e spazio colore vanno versionati insieme ai pesi.
- **La compressione modifica il segnale.** Una ricompressione applicata per ragioni di distribuzione o di archiviazione cambia l'ingresso del modello a monte di ogni scelta di modellazione.
- **Differenze fra development e production.** Una libreria di decodifica diversa, un ordine dei canali diverso, un'interpolazione diversa producono discrepanze difficili da diagnosticare a valle.
- **Versionamento del dato.** Il training set va identificato in modo univoco, con la sua procedura di costruzione (DVC è standard de facto).

Una discrepanza di preprocessing fra addestramento e produzione è fra le cause più frequenti di degrado inspiegato delle prestazioni.



GRAZIE PER L'ATTENZIONE

Domande?

Giacomo Nunziati giacomo.nunziati.0@gmail.com