



MODULO 2

Modelli predittivi su dati tabellari clinici



Obiettivi e struttura della lezione



Argomenti della lezione

- **I dati:** valori mancanti strutturali, feature engineering su valori di laboratorio, feature selection e sua stabilità.
- **I modelli:** dalla regressione logistica ai modelli additivi, al gradient boosting, alle reti tabellari e ai modelli fondazionali.
- **La spiegazione:** interpretabilità globale e locale, metodi intrinseci e post-hoc, e i loro limiti documentati.
- **La valutazione:** metriche su classi sbilanciate, calibrazione delle probabilità, quantificazione dell'incertezza, protocolli di validazione clinica.
- **La produzione:** monitoraggio, aggiornamento, e i vincoli normativi che decidono dove il modello può girare.

Il filo è uno solo: seguire il numero prodotto dal modello dal dato che entra alla decisione che esce, e vedere in ciascun punto che cosa lo rende inaffidabile.



PASSO 1

Predizione su dati tabellari clinici

Definizione del problema

Dato un insieme di variabili anagrafiche e di risultati di analisi di laboratorio riferiti a un singolo paziente in un singolo momento, stimare la probabilità che una determinata condizione clinica sia presente.

- l'uscita desiderata è un suggerimento per un clinico
- le variabili disponibili **possono cambiare da paziente a paziente** (missing data)
- la condizione da individuare è tipicamente **rara** nella popolazione osservata

Caratteristiche dei dati tabellari

Immagini, testo, segnali

- le componenti sono omogenee e confrontabili fra loro
- spesso esiste una struttura locale (feature spazialmente o temporalmente vicini sono correlati)
- l'ordine delle componenti è informativo
- i dataset di riferimento sono grandi

Dati tabellari

- ogni attributo ha unità, scala e semantica proprie
- nessuna struttura locale: le colonne non hanno correlazioni note a priori
- l'ordine delle colonne è arbitrario
- i dataset clinici sono tipicamente piccoli

Da queste differenze discende il fatto empirico che sui dati tabellari gli alberi di decisione restano competitivi con le architetture neurali, che invece dominano altrove.



Struttura di un record clinico

GRUPPO	ESEMPI	TIPO	DISPONIBILITÀ
anagrafica	età, sesso	continua, binaria	sempre presente
anamnesi	interventi pregressi, gravidanza	binaria	sempre presente
terapie in corso	farmaco sostitutivo, farmaco soppressivo	binaria	sempre presente
sospetti del clinico	quesito diagnostico posto in richiesta	binaria	sempre presente
esami di laboratorio	valori dosati nel siero	continua	variabile
indicatori di esecuzione	l'esame è stato eseguito o no	binaria	sempre presente
provenienza	struttura che ha inviato il paziente	categorica	sempre presente

Le feature provenienti da esami di laboratorio sono tipicamente molto informative, ma la loro presenza è variabile: la gestione dei missing data diventa cruciale.




Domini di applicazione

- **Diagnosi e stratificazione del rischio** a partire da esami di routine: individuare i pazienti da approfondire.
- **Prognosi**: probabilità di un evento entro un orizzonte temporale definito.
- **Triage e prioritizzazione** in contesti a risorse limitate.
- **Predizione di riammissione o di complicanza** dopo un ricovero.
- **Medicina di laboratorio**: controllo di plausibilità dei referti e individuazione di risultati anomali.

In tutti i casi il modello non sostituisce una decisione (che resta in capo al clinico), ma la supporta.

Ordinamento vs probabilità



- Il primo caso richiede solo che l'ordinamento sia corretto. La scala dei valori è irrilevante.
- Il secondo caso richiede che **l'output sia interpretabile** (e.g. probabilità).

Discriminazione, calibrazione, utilità clinica

Discriminazione

«il modello distingue casi positivi e negativi?»

C-statistic · curva precision-recall

Calibrazione

«la predizione è interpretabile?»

reliability diagram · pendenza e intercetta

Utilità clinica

«l'output aiuta nelle decisioni cliniche?»

curva di decisione · net benefit

Il caso in esame

3.772

pazienti

29

variabili

6 %

prevalenza


- **UCI Thyroid Disease**: predizione di una condizione tiroidea da anagrafica, anamnesi ed esami di laboratorio.
- **Sei esami somministrabili**, ciascuno accompagnato da un flag che indica se è stato eseguito. Il dataset rende quindi **esplicita, riga per riga**, i missing data.
- Un esame non è stato somministrato in **nessun** paziente della raccolta: un caso limite utile.
- Le classi sono fortemente sbilanciate, in rapporto di circa **quindici a uno**.



PASSO 1.5

Criticità del problema in esame

Valori mancanti strutturali



- Non tutti i pazienti ricevono lo stesso insieme di analisi.
- L'assenza di alcune feature è **un risultato naturale** del processo che "genera" i dati (i flussi di lavoro clinici).
- Lo stesso vale in inferenza: il modello in produzione riceverà record incompleti.

Un modello addestrato sui soli casi completi è tarato su una popolazione che in inferenza non esiste.



Meccanismi all'origine dei dati mancanti

Sia X il dato completo e M la maschera che indica quali valori sono osservati.

MECCANISMO	DA COSA DIPENDE M	ESEMPIO CLINICO
MCAR <i>missing completely at random</i>	da niente	provetta rotta in trasporto
MAR <i>missing at random</i>	solo dalle parti osservate di X	il panel di esami di laboratorio dipende dal reparto, che è registrato
MNAR <i>missing not at random</i>	anche dalle parti non osservate di X	l'esame non è stato chiesto perché il paziente appariva sano
self-masking	dal valore stesso che manca	caso particolare di MNAR, il più frequente in clinica

La distinzione non è verificabile dai dati. Da un dataset non si può dimostrare che il meccanismo sia MAR: è un'ipotesi sul processo clinico.

Terminologia introdotta da Rubin (1976); la trattazione moderna in predizione è in Josse et al., *On the consistency of supervised learning with missing values*, Statistical Papers 2024.


Missingness informativa e self-masking

La missingness è informativa quando la maschera M porta informazione sull'esito che i valori osservati non contengono già.

- il predittore ottimo dipende **dalla maschera oltre che dai valori**
- i pattern di missingness possibili sono 2^p : costruire un metodo che li tratta separatamente è infattibile
- l'informazione contenuta nella maschera riguarda **il comportamento del clinico**

Conseguenza in production: la maschera di missingness dipende dal protocollo clinico, che è soggetto a drift.

Sbilanciamento delle classi



- Nei problemi diagnostici la condizione da individuare è tipicamente presente in una frazione piccola della popolazione osservata.
- **L'accuratezza diventa inutilizzabile.**
- L'addestramento risente della scarsità: la loss function è dominata dalla classe maggioritaria.
- Il vincolo statistico è il **numero di eventi positivi**, che determina l'incertezza su ogni metrica.

Costo asimmetrico degli errori

Falso negativo

- una condizione presente non viene segnalata
- il caso non viene approfondito
- il costo è clinico (ritardo nel trattamento) e differito nel tempo
- spesso non viene mai osservato

Falso positivo

- un paziente sano viene inviato ad approfondimento
- costo economico, di tempo e di ansia
- il costo è immediato e misurabile
- viene sempre osservato

Il rapporto fra i due costi è definito dalle soglie scelte in fase di calibrazione dei modelli, ed è dettato anche da considerazioni cliniche.

Data leakage nei dati clinici

- **Definizione.** Una variabile disponibile in addestramento che in produzione non esiste, o che contiene informazione ottenuta a valle del fenomeno da predire.
- **Variabili post-evento:** terapie iniziate dopo la diagnosi, codici di dimissione, successivi accertamenti.
- **Variabili di processo:** reparto di provenienza, tipo di richiesta, urgenza. Codificano il **sospetto già formulato dal clinico**.
- **La maschera di missingness stessa,** quando l'esame è stato prescritto proprio perché esisteva un sospetto clinico.

In molti casi la mitigazione dei leakage può avvenire solo tramite ricostruzione del flusso di raccolta dei dati, e valutazione delle singole variabili con supporto di esperti di dominio.

Numerosità limitata degli eventi

- Nei modelli di predizione clinica il campione utile non si conta in righe: si conta in **eventi**, cioè casi della classe minoritaria.
- Da lì dipende l'incertezza su ogni stima: metriche, coefficienti, forma delle funzioni apprese.
- Con poche decine di eventi, l'intervallo di confidenza su una metrica può essere più largo della differenza fra due modelli che si vogliono confrontare.
- Le regole empiriche storiche — dieci eventi per variabile, cento eventi per una validazione — sono state mostrate inaffidabili e sostituite da calcoli mirati.

Il dimensionamento del campione chiude il Passo 4, ed è la stessa questione vista dal lato della progettazione anziché da quello della misura.



PASSO 2

Costruzione e preprocessing dei dati



Tipi di variabile e loro trattamento

TIPO	ESEMPI	TRATTAMENTO
continua misurata	valore somministrato di un farmaco	standardizzazione, oppure nessun preprocessing (se il modello è ad albero)
continua derivata	rapporto fra due valori di laboratorio	ricalcolata, se necessario
categorica ordinale	classe di severità	codifica che conserva l'ordine
categorica nominale	struttura di provenienza	one-hot
binaria	terapia in corso, sesso	nessuno
indicatore di esecuzione	l'esame è stato eseguito	nessuno (la maschera di missingness)

Le variabili derivate vanno ricalcolate dopo l'imputazione, non imputate: un rapporto imputato non è coerente con i suoi ingressi e introduce contraddizioni che il modello impara.

Trattamento dei valori mancanti: panoramica

FAMIGLIA	ESEMPI	CHE COSA ASSUME	COSTO
cancellazione dei casi	complete-case analysis	che i casi completi siano rappresentativi	perdita di dati, distorsione
imputazione con costante	media, mediana, valore fisso	che il modello a valle sia flessibile	nullo
imputazione multipla	MICE, imputazione iterativa	un modello per colonna a partire dalle altre	alto, e va replicata in inferenza
basata sui vicini	kNN imputer	che la somiglianza sulle colonne presenti basti	alto in inferenza
indicatore di missingness	colonna binaria aggiuntiva	che l'assenza porti informazione	nullo, ma fragile
gestione nativa nel modello	alberi con MIA	niente: l'assenza è una direzione dello split	nullo
modelli per pattern	pattern submodels	un modello per ogni pattern osservato	esponenziale
architetture dedicate	NeuMiss	una forma parametrica del predittore ottimo	implementativo

Nessuna riga di questa tabella è «la soluzione corretta». La scelta dipende dal meccanismo assunto e dal costo che si può sostenere in inferenza, non da un confronto di accuratezza.

Indicatori di missingness

- **Costruzione.** Per ogni variabile che può mancare si aggiunge una colonna binaria che dice se il valore è presente. Il modello riceve valori e maschera insieme.
- **Quando aiuta.** Quando la missingness è informativa: l'indicatore è il canale attraverso cui l'informazione arriva al modello.
- **Quando è ridondante.** Quando il modello gestisce già i valori assenti nativamente: l'indicatore duplica un'informazione che il modello ha già.
- **Perché è fragile.** L'indicatore codifica una **prassi operativa**. Se il protocollo di prescrizione cambia, la regola appresa diventa falsa, e le metriche calcolate sul vecchio test set restano buone.

In letteratura clinica il bilancio è controverso: alcuni studi riportano un guadagno in scenari MNAR, altri nessuna differenza, e tutti segnalano il rischio di generalizzazione fra contesti diversi.

Alberi con MIA


A ogni split, l'albero decide dove mandare i record in cui quella variabile manca. Ha tre possibilità.



- La scelta è **appresa**: vince quella che riduce di più la funzione di costo.
- Vale split per split, quindi la stessa variabile può mandare gli assenti a sinistra in un nodo e a destra in un altro.

MIA — Missing Incorporated in Attribute. L'albero non «gestisce» i valori assenti: li usa come informazione.

Valori mancanti in addestramento e in inferenza



- rifiutare la **predizione** e delegare a un operatore
- **imputare**, con le statistiche del training set
- usare un **modello addestrato sul sottoinsieme** di colonne disponibili
- gestione nativa del modello

L'ultima opzione ha una criticità: il contributo associato all'assenza di una variabile è stimato sui casi in cui quella variabile mancava in addestramento: se sono pochissimi, il parametro è di fatto non addestrato.




Feature engineering su dati di laboratorio

- **Indicatori clinici noti in letteratura.** Molti indici clinici consolidati sono ottenuti con formule sui valori misurati. Per individuarli è necessaria una ricerca in letteratura o il supporto di un esperto di dominio.
- **Differenze rispetto a un riferimento.** Distanza dal limite superiore o inferiore dell'intervallo di normalità, in valore assoluto o in multipli dell'ampiezza.
- **Fasce di severità note.** Hanno il vantaggio di rendere il modello più interpretabile per chi lo userà.
- **Aggregazioni.** Numero di misure di laboratorio fuori range, numero di misure complessive.

Su dati clinici, a causa della loro scarsità, la conoscenza di dominio risulta particolarmente utile e spesso investire in questo aspetto garantisce un ritorno maggiore.

Range di riferimento



- Il clinico legge il referto in tre categorie: **sotto, dentro, sopra** l'intervallo.
- Il modello vede solo un numero su una scala continua: quell'intervallo non lo conosce.
- L'intervallo **cambia con età e sesso**: lo stesso valore non significa la stessa cosa in due pazienti.
- Passare al modello **la posizione rispetto all'intervallo**, e non solo il valore, gli dà l'informazione che il clinico usa.

Preprocessing e prevenzione del leakage

- **Le statistiche si calcolano sul solo training set.** Medie, deviazioni standard, valori di imputazione, quantili, codifiche delle categoriche.
- **La selezione delle variabili sta dentro la cross-validation**, non prima. Selezionare su tutto il dataset e poi validare produce una stima ottimistica.
- **Lo split rispetta la struttura dei dati.** Se un paziente compare più volte, tutte le sue righe stanno dalla stessa parte. Se i dati vengono da centri diversi, lo split casuale non misura la generalizzazione che interessa.
- **Il preprocessing fa parte del modello** e va versionato con i pesi. In produzione va applicato identico, nella stessa sequenza.



PASSO 3

Dalla baseline ai modelli avanzati

Baseline: regressione logistica

Il modello di riferimento storico per il rischio clinico. Un coefficiente per variabile, e il logit della probabilità come somma dei contributi.

$$\text{logit } p(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

- Ogni coefficiente ha un'interpretazione diretta: **odds ratio** per unità di variabile.
- È la forma di molti punteggi di rischio in uso clinico.
- **Il limite.** Assume che l'effetto di ogni variabile sul logit sia lineare: sui valori di laboratorio il rischio sale a entrambe le code, e una retta non può rappresentarlo.

Rappresentando molti modelli realmente in uso, costituisce un ottimo punto di partenza. Il passo successivo abbandona la linearità e tiene l'additività.

GAM — Generalized Additive Models

I **GAM** sostituiscono ogni coefficiente con una funzione stimata dai dati. La forma della dipendenza è appresa.

LINEARE $\text{logit } p(x) = \beta_0 + \sum_j \beta_j x_j$

GAM $\text{logit } p(x) = \beta_0 + \sum_j f_j(x_j)$


- Ogni f_j è una **shape function**: una relazione che si può valorizzare su ogni record.
- Si perde la linearità, si conserva la **somma**: il contributo di ogni variabile resta separabile dagli altri.
- L'additività rendere il modello interpretabile.

Stima delle shape function


Ogni curva viene **stimata dai dati**, una variabile alla volta.



f_1
età



f_2
primo analita



f_3
secondo analita

- Non serve dire in anticipo dove sono le soglie: le trova la stima.
- Il risultato è una curva per variabile, che si guarda e si discute con il clinico.

È la stessa lettura del referto: rischio in funzione del valore, un grafico per esame.

Interazioni: modelli GA2M


$$\text{logit } p(x) = \beta_0 + \sum_j f_j(x_j) + \sum_{(j,k)} f_{jk}(x_j, x_k)$$



- Il modello additivo puro non rappresenta le interazioni: l'effetto di una variabile non può dipendere dal valore di un'altra. Il **GA2M** aggiunge termini su coppie di variabili, selezionate automaticamente durante l'addestramento.
- Ogni f_{jk} è una **funzione di due variabili**, $R^2 \rightarrow R$, stimata a gradini su una griglia di bin: per questo si disegna come heatmap.

Il numero di coppie ammesse è un iperparametro, e i valori predefiniti sono generosi: la leggibilità è reale sulle curve singole, sulle coppie è nominale.


Explainable Boosting Machine



- È un **GA2M addestrato con boosting ciclico**: prima i termini univariati, poi le coppie selezionate.
- Il passo è deliberatamente piccolo e i giri sono molti, così che l'ordine delle variabili non conti.
- Ogni variabile riceve una **categoria dedicata per i valori assenti**, con un contributo proprio, stimata come gli altri.
- Il costo di addestramento è di uno o due ordini di grandezza superiore a quello di un gradient boosting non vincolato sullo stesso dato.

Implementato nella libreria `interpret`, con licenza MIT.

Non identificabilità dei modelli additivi



- Una costante spostata da una componente all'altra **non cambia la predizione**. Serve un vincolo aggiuntivo per rendere la scomposizione unica.
- Con **variabili correlate** il problema si amplifica.
- Se si cerca di interpretare le shape function, due modelli equivalenti in predizione possono suggerire letture cliniche diverse.



Decision tree e random forest

- **L'albero singolo** partiziona lo spazio con soglie su singole variabili. È leggibile finché resta poco profondo, e instabile: piccole variazioni nei dati cambiano la struttura.
- **Il random forest** media molti alberi addestrati su resampling e sottoinsiemi di variabili. Riduce la varianza, perde l'interpretabilità.
- **Pregi pratici:** pochi iperparametri, addestramento rapido, gestione implicita dei valori assenti, e nessuna necessità di standardizzare.

Gradient boosting



- Ogni albero è addestrato a correggere l'errore dei precedenti.
- Gli alberi sono **deliberatamente poco profondi** e il learning rate è piccolo.
- Gli iperparametri principali sono tre: numero di alberi, profondità, learning rate. Si influenzano a vicenda.
- La regolarizzazione avviene per subsampling di righe e colonne, e per penalizzazione sulla dimensione degli alberi.

Baseline di riferimento su dati tabellari.

XGBoost, LightGBM, CatBoost

XGBoost

PRINCIPIO

Crescita **per livello**: l'albero si espande un piano alla volta.

PRO

Comportamento prevedibile, la più collaudata, ottimo supporto ai vincoli di monotonicità.

CONTRO

Le variabili categoriche vanno codificate a mano.

LightGBM

PRINCIPIO

Crescita **per foglia**: espande la foglia che promette il guadagno maggiore.

PRO

La più rapida sui dataset grandi; gestisce le categoriche nativamente.

CONTRO

Su pochi dati va più facilmente in overfitting.

CatBoost

PRINCIPIO

Alberi **simmetrici** e **target encoding ordinato** per le categoriche.

PRO


Robusto sui dataset piccoli, spesso il meglio calibrato.

CONTRO

Più lento; i valori assenti finiscono sempre allo stesso estremo.

Le differenze di accuratezza fra i tre sono tipicamente entro l'incertezza della misura. Si scelgono per come trattano categoriche, valori assenti e campioni piccoli.

Vincoli di monotonicità



- **Quando.** Quando si sa già che l'effetto va in una sola direzione: più alto il valore, più alto il rischio.
- **Perché.** Dove i dati sono pochi il modello disegna avvallamenti che non esistono. Una curva che scende dove non dovrebbe è un errore evidente per chi conosce il dominio, e fa perdere fiducia in tutto il modello.
- **Come.** Si dichiara il vincolo prima dell'addestramento: durante la costruzione degli alberi vengono scartati gli split che lo violerebbero.
- **Quanto costa.** Quasi niente in accuratezza: si sta aggiungendo un'informazione vera, non limitando il modello.

Modelli bayesiani

Invece di un solo valore per ogni parametro, si stima una **distribuzione** di valori possibili.

$$p(\theta \mid \text{dati}) \propto p(\text{dati} \mid \theta) \cdot p(\theta)$$

a sinistra ciò che si conclude sui parametri, poi quanto i dati sono compatibili con essi, poi ciò che si assumeva prima di vederli.

vantaggi

- Dà un'incertezza **sul modello**, non solo sulla singola predizione.
- Permette di inserire conoscenza di dominio come distribuzione a priori.
- Regge meglio quando i dati sono pochi.

svantaggi

- Il costo di calcolo cresce rapidamente con il numero di osservazioni.
- Su dati tabellari **non è competitivo** con il gradient boosting.
- Le distribuzioni a priori sono una scelta in più da giustificare.

UN ESEMPIO

Regressione logistica bayesiana. Stessa forma della baseline, ma ogni coefficiente β_j è una distribuzione invece di un numero. Il risultato non è «l'effetto dell'analita A è +0,4», è «è +0,4, plausibilmente fra +0,1 e +0,7». Su un paziente si ottiene così **un intervallo sulla probabilità predetta**, non un solo valore.

Modelli additivi neurali

Stessa struttura additiva dei GAM, ma ogni shape function è una **piccola rete neurale**.

$$\text{logit } p(x) = \beta_0 + \sum_j \text{rete}_j(x_j)$$

una rete per variabile, addestrate insieme · varianti principali: NAM, NODE-GAM, GAMI-Net

vantaggi

- Sono differenziabili, quindi si addestrano insieme al resto di una pipeline.
- Alcune varianti danno un'incertezza sulle singole curve.
- Su dataset grandi e con molte interazioni vanno meglio degli additivi ad albero.

svantaggi

- Servono molti dati: su tabellari piccoli non battono gli alberi.
- Addestramento più lento e più iperparametri da scegliere.

Utili quando la tabella va addestrata insieme a un'altra modalità, o quando serve un modello differenziabile end-to-end. Ma richiede molti dati.



Modelli ibridi

FORMA	MECCANISMO	VANTAGGIO
interpretabile con delega	il modello leggibile decide dove è competente, il resto va a un modello non vincolato	è noto quali casi hanno ricevuto una decisione spiegabile
additivo con correzione residua	un modello additivo cattura la parte principale, un boosting impara il residuo	completamente spiegabile, se si accettano i due layer di interpretabilità
forma additiva estratta	si addestra un boosting con vincoli di interazione e lo si scompone in componenti leggibili	leggibilità a posteriori senza rinunciare all'addestramento non vincolato
distillazione	un modello complesso genera le etichette con cui si addestra un modello semplice	modello distillato leggibile e leggero

La prima forma è la più adatta a un contesto clinico, perché rende esplicito il sottoinsieme di pazienti su cui il sistema è in grado di motivare la propria uscita.



Metodi non trattati (review, primo passo)

METODO	AMBITO	RIFERIMENTO
NeuMiss	architettura per il predittore ottimo con valori assenti	Le Morvan et al., NeurIPS 2020
pattern submodels	un modello per ciascun pattern di missingness	letteratura statistica su dati incompleti
MICE, regole di Rubin	imputazione multipla con inferenza corretta	Rubin 1987; van Buuren 2018
missForest	imputazione iterativa con random forest	Stekhoven, Bühlmann 2012
ProtoNAM, Neural Basis Models	varianti di modelli additivi neurali	letteratura 2023–2025
analisi di sopravvivenza	esito con tempo all'evento e censura	Cox 1972 e successivi
modelli causali	effetto di un intervento, non predizione	letteratura su inferenza causale
fairness e disparità di sottogruppo	equità delle prestazioni fra popolazioni	letteratura dedicata



PASSO 3.5

Interpretabilità



Interpretabilità globale e locale


Globale

- descrive il comportamento del modello nel suo insieme
- quali variabili hanno maggior impatto, e in quale direzione
- serve alla validazione, alla documentazione, al confronto con la conoscenza di dominio
- non dipende dal singolo record

Locale

- spiega **una** predizione
- serve durante l'uso clinico, davanti a un caso concreto
- varia da caso a caso, e la sua stabilità va valutata

Lettura di una shape function



- L'asse verticale è il **contributo al logit**. Sopra lo zero la variabile aumenta il rischio, sotto lo riduce.
- La **pendenza** dice dove il rischio cambia più in fretta; i tratti piatti sono intervalli in cui il valore non fa differenza.
- L'istogramma dà il **numero di casi per intervallo**. Dove è basso — tipicamente le code — la curva è stimata su pochi dati.

La curva è la spiegazione: non c'è un secondo modello che stima cosa il primo ha fatto.

Metodi post-hoc

Si applicano a modelli già addestrati, senza toccarli: si osserva **come si comporta** cambiando gli ingressi e osservando le uscite (black box).

- **Il vantaggio.** Si applicano a qualunque modello, anche a uno che non è stato progettato per essere leggibile.
- **Il limite.** Producono una **stima** del comportamento del modello, non il comportamento stesso (stima soggetta a errori).

I TRE CHE VEDIAMO

- 1 **Permutation importance** — quanto il modello stimatore si appoggia a una variabile
- 2 **Partial dependence** — l'effetto medio di una variabile sulle predizioni
- 3 **SHAP** — il contributo di ogni variabile a una singola predizione

Esistono altri metodi — LIME, controfattuali, ICE — che rispondono a domande simili con gli stessi limiti.

Permutation e partial dependence


...	4,2	...	shuffle →	...	9,1	...
...	1,8	...		...	3,0	...
...	9,1	...		...	1,8	...

Gli stessi valori, assegnati ad altri pazienti: la colonna resta plausibile ma **perde ogni legame con l'esito**.

- **Permutation importance.** Si rimescolano i valori di una colonna fra le righe e si misura di quanto peggiora la metrica. Se peggiora molto, il modello si appoggiava a quella variabile.
- Se due variabili sono fortemente correlate, rimescolandone una il modello potrebbe recuperare l'informazione dall'altra: la metrica non cala e sembrano entrambe inutili.
- **Partial dependence.** Si fissa una variabile a un valore, si predice su tutti i pazienti, si fa la media; ripetendo su una griglia di valori si ottiene la curva dell'effetto medio. Problema: si costruiscono esempi out-of-distribution.

Valori di Shapley e SHAP


Il modello predice **0,36** per questo paziente e in media **0,06**: SHAP **distribuisce la differenza** fra le variabili. Ogni barra parte dove finisce la precedente.



- Il contributo è quanto la variabile **sposta la predizione** quando viene aggiunta alle altre, mediato su **tutti gli ordini** di aggiunta possibili. Sommati, ricostruiscono esattamente lo scarto dalla media.
- Il calcolo esatto costa 2^p valutazioni. Sugli alberi esiste **TreeSHAP**, che lo risolve in tempo polinomiale: è la ragione per cui SHAP è diventato lo standard sui dati tabellari.
- TreeSHAP ha però **due varianti** — *conditional* e *interventional* — che simulano in modo diverso l'assenza di una variabile e danno risultati diversi sullo stesso modello. La libreria sceglie in base agli argomenti che le si passano: va dichiarato quale si è usata.

Le proprietà valgono per i valori esatti; con l'approssimazione valgono in modo approssimato.

Disaccordo fra metodi di spiegazione



- Metodi diversi applicati allo stesso modello producono ordinamenti diversi, e la discordanza cresce con la correlazione fra le variabili.
- **Non esiste una ground truth:** l'importanza reale di una variabile non è una quantità osservabile, quindi non si può stabilire quale metodo sbaglia.
- Il fenomeno è documentato in modo sistematico e riguarda anche coppie di metodi che misurano nominalmente la stessa cosa.

Conseguenza operativa: l'attribuzione serve a generare ipotesi da verificare con un esperimento o con la conoscenza di dominio, mai come prova a sostegno di una conclusione.



Destinatari della spiegazione

DESTINATARIO	DOMANDA	FORMA ADATTA	QUANDO SERVE
clinico	«posso fidarmi della predizione su questo caso?»	contributi del singolo caso, in unità cliniche	al momento della decisione
paziente	«perché sono stato segnalato?»	poche frasi in linguaggio naturale	su richiesta
ente regolatore	«quali variabili sono state usate?»	descrizione globale, documentazione del modello	in fase di approvazione
sviluppatore	«dove sbaglia?»	analisi degli errori, casi limite, stabilità	in fase di sviluppo



PASSO 4

Valutazione: metriche, calibrazione, incertezza



Metriche di classificazione binaria



METRICA	INTERPRETAZIONE	QUANDO È FUORVIANTE
accuratezza	frazione di predizioni corrette	classi sbilanciate: la si massimizza rispondendo sempre «negativo»
recall	quota di positivi individuati	da sola non dice quanti falsi positivi costa
specificità	quota di negativi riconosciuti	a bassa prevalenza è quasi sempre altissima
precision	quota di segnalazioni corrette	dipende dalla prevalenza, quindi non trasferisce fra popolazioni
F1	media armonica di precision e recall	pesa recall e precision in modo simmetrico
AUROC	probabilità di ordinare correttamente una coppia	non dice niente sulla calibrazione

Metriche su classi sbilanciate

- **L'accuracy non è informativa.** Con prevalenza al 6 % un classificatore che predice sempre la classe negativa raggiunge il 94 %.
- **La baseline della curva precision-recall è la prevalenza**, non 0,5. Un'average precision di 0,30 con prevalenza 0,06 corrisponde a un fattore cinque sul caso.
- **La precision dipende dalla prevalenza**, quindi non si trasferisce fra popolazioni: a soglia invariata, lo stesso modello ha precision diversa in un contesto con prevalenza diversa.
- **Sensibilità e specificità si trasferiscono**, essendo condizionate alla classe vera. Per questo la letteratura clinica le riporta come descrittori primari.

Un valore di average precision va sempre riportato insieme alla prevalenza del campione su cui è calcolato.

Curva ROC e curva precision-recall



- **La ROC** divide i falsi positivi per tutti i negativi: a bassa prevalenza sono moltissimi.
- **La precision-recall** li divide per le segnalazioni fatte: lo stesso peggioramento si vede.


Non è che una curva sia giusta e l'altra sbagliata: rispondono a due domande. A bassa prevalenza, l'impressione che danno è molto diversa.

Scelta della soglia operativa

- **Il modello restituisce un punteggio continuo;** la decisione binaria richiede una soglia, che non fa parte dell'addestramento ed è una scelta a valle.
- **Precision a recall fissato.** È la forma in cui il requisito arriva dal clinico: fissata la sensibilità richiesta, si misura il volume di falsi positivi che ne consegue.
- **Massimizzare F1 è una scelta implicita.** Fissa un rapporto fra i costi dei due errori uguale per ogni contesto, senza dichiararlo.
- **La soglia è legata alla popolazione.** A prevalenza diversa, la stessa soglia produce un punto di lavoro diverso, e va rivista.

La soglia si deriva dal rapporto fra i costi dei due errori, che si formalizza con gli strumenti di utilità clinica alla fine del passo.

Intervalli di confidenza sulle metriche



- La metrica calcolata su un test set è una **stima**, e dipende da quello specifico test set.
- Il **bootstrap** — resampling con reimmissione delle righe del test set — dà un intervallo di confidenza attorno alla stima.
- L'intervallo dice **se il confronto è possibile**. Se gli intervalli dei due modelli si sovrappongono, il confronto è poco informativo.

L'intervallo va riportato sempre: è l'informazione che dice se un confronto ha senso.



Confronto fra due modelli


APPROCCIO	PROCEDURA	QUANDO USARLO
confronto di intervalli separati	si guardano i due intervalli e si controlla se si sovrappongono	da evitare: ignora che i modelli sono valutati sugli stessi casi ed è troppo conservativo
bootstrap sulla differenza appaiata	a ogni resampling si calcolano entrambe le metriche e si prende la differenza	confronto fra metriche continue sullo stesso test set
test di McNemar	tabella delle discordanze fra le due decisioni binarie	confronto fra decisioni a soglia fissata
validazione ripetuta	si ripete l'intero protocollo su split diversi	quando il test set è piccolo e si può ricampionare l'addestramento

Calibrazione: definizione

Un modello è calibrato quando, fra tutti i casi ai quali assegna probabilità p , la frazione di positivi osservata è p . Questo deve valere per ogni valore di p .

- **in media** — la media delle probabilità predette uguaglia la prevalenza osservata
- **debole** — pendenza di calibrazione pari a 1 e intercetta pari a 0
- **moderata** — la definizione qui sopra, per ogni valore di p
- **forte** — la stessa proprietà **dentro ogni sottogruppo** della popolazione

Reliability diagram



- Le predizioni si raggruppano in **bin**; per ciascuno si confronta la probabilità media predetta con la frazione di positivi osservata.
- La **diagonale** è la calibrazione perfetta. I punti sotto la diagonale indicano un modello che sovrastima il rischio.
- Il **numero e il tipo di bin** cambiano l'aspetto del grafico, e non esiste una scelta neutra.
- A prevalenza bassa quasi tutte le predizioni cadono nei primi bin, e il resto del grafico è stimato su pochissimi casi.

Per questo la letteratura clinica non si affida all'ispezione visiva, ma a due statistiche che non dipendono dai bin.

Pendenza e intercetta di calibrazione

Si adatta una regressione logistica che ha come unica variabile il logit delle probabilità predette, e come esito l'evento osservato.


calibrazione.txt

```
logit p_oss = a + b * logit p_pred
b = 1, a = 0    -> calibrato
b < 1           -> predizioni troppo estreme
b > 1           -> predizioni troppo compresse verso il centro
a != 0          -> errore sistematico di livello: prevalenza sbagliata
```


- **Non dipendono dai bin**, a differenza del reliability diagram.
- I due parametri separano due difetti diversi: b riguarda la dispersione, a il livello.
- **Calibrazione in the large**: si fissa $b = 1$ e si stima il solo a. È la forma che interessa quando cambia solo la prevalenza.

Sono il linguaggio standard nella letteratura sui modelli di predizione clinica, e vanno riportati entrambi.

Proprietà della ricalibrazione




probabilità: si spostano



ordinamento: identico

- Tutti i metodi di ricalibrazione sono **trasformazioni monotone** del punteggio.
- Ne discende che **l'ordinamento dei casi non cambia**: l'AUROC e l'area sotto la curva precision-recall restano invariate.
- Se il problema è la scelta di **chi approfondire per primo**, la ricalibrazione non serve a niente.
- Se il problema è **usare il valore come una probabilità** — confrontarlo con una soglia, comunicarlo a un paziente, combinarlo con un costo — allora è indispensabile.

Shift di prevalenza



- È la forma di shift più comune in ambito clinico: cambia **quanto è frequente** la condizione, non **come si manifesta**.
- La relazione fra variabili ed esito resta la stessa, quindi il modello continua a ordinare correttamente i pazienti.
- Le probabilità però sono calcolate rispetto alla vecchia prevalenza, quindi risultano sistematicamente troppo basse o troppo alte.
- La soglia scelta sulla popolazione di sviluppo produce, sulla nuova, un punto di lavoro diverso da quello previsto.

Si diagnostica con l'intercetta di calibrazione e con il confronto fra probabilità media predetta e prevalenza osservata. Esistono tecniche di correzione dello shift di prevalenza.

■ Incertezza aleatoria ed epistemica

Aleatoria

- rumore intrinseco del fenomeno
- due pazienti identici sulle variabili disponibili possono avere esiti diversi
- **non si riduce** raccogliendo più dati
- si riduce solo misurando variabili nuove

Epistemica

- ignoranza del modello
- alta dove i dati di addestramento sono radi o assenti
- **si riduce** raccogliendo più dati

La distinzione è operativa, in quanto solo l'incertezza epistemica giustifica la raccolta di nuovi dati.

Predizione selettiva e astensione



- **Esempi di regole di astensione:** due soglie anziché una, con una zona grigia in mezzo; soglia sull'incertezza stimata.
- **I due parametri della scelta:** il costo di un errore rispetto al costo del lavoro umano; la capacità disponibile — un tasso di astensione che eccede il numero di operatori non è applicabile, per quanto sia giustificato.



Protocolli di validazione

PROTOCOLLO	COME SI COSTRUISCE	CHE COSA STIMA
hold-out singolo	una divisione casuale in due parti	stima con varianza alta, dipende dalla divisione
k-fold cross-validation	k divisioni, ogni parte usata una volta come test	performance media, con stima della variabilità
cross-validation ripetuta	più ripetizioni di k-fold con semi diversi	riduce la dipendenza dalla singola partizione
bootstrap	resampling con ripetizione	validazione interna, raccomandata su campioni piccoli
validazione esterna	dati di un altro centro o di un altro periodo	trasportabilità del modello

Validazione esterna e temporale

Esterna, per centro

- si addestra su alcune strutture e si valuta su una (o altre) nuova.
- cambia la popolazione, il protocollo, talvolta la strumentazione
- il numero di centri disponibili è quasi sempre piccolo

Temporale

- si addestra sui dati fino a una data e si valuta su quelli successivi
- cambiano prassi, definizioni, popolazione afferente



PASSO 5

Production e manutenzione

Monitoraggio in assenza di etichette

- **Il problema.** In un sistema clinico l'esito reale arriva mesi dopo, oppure non arriva mai, perché il paziente segnalato viene trattato e l'esito avverso non si osserva.
- **Drift delle variabili in ingresso.** Distribuzione di ciascuna variabile, frazione di valori assenti, comparsa di codici nuovi. Si confronta con la distribuzione di addestramento.
- **Drift della distribuzione delle probabilità predette.** È il segnale precoce di un cambio di prevalenza, e non richiede etichette: se la media delle predizioni si sposta, qualcosa è cambiato a monte.
- **Tasso di astensione e frazione di casi fuori distribuzione.** Salgono prima che salgano gli errori, e sono la spia più utile fra quelle disponibili senza esiti.

Sono indicatori del fatto che le condizioni in cui è stato validato non valgono più.

Regolamentazione dei dispositivi medici

- **Quando un software è dispositivo medico.** Se è destinato dal fabbricante a scopo di diagnosi, prevenzione, monitoraggio, previsione o prognosi, ricade nel regolamento europeo sui dispositivi medici. La destinazione d'uso dichiarata è il criterio.
- **La classificazione.** Il software che fornisce informazioni usate per decisioni diagnostiche o terapeutiche ricade in classi che richiedono l'intervento di un organismo notificato.
- **Il regolamento europeo sull'intelligenza artificiale** classifica ad alto rischio i sistemi che sono componenti di sicurezza di un dispositivo medico, e aggiunge obblighi su gestione del rischio, qualità dei dati, documentazione tecnica e sorveglianza umana.
- **Le conseguenze progettuali.** Tracciabilità delle versioni, giustificazione delle scelte di modellazione, e limiti alla possibilità di aggiornare il modello senza rivalutazione.

Sono vincoli di progetto e decidono se il modello può essere aggiornato automaticamente, e talvolta quale famiglia di modelli è sostenibile.




Trattamento dei dati sanitari

- **Categoria particolare.** I dati relativi alla salute ricevono una tutela rafforzata: il trattamento è vietato salvo specifiche condizioni, e richiede una base giuridica adeguata.
- **Minimizzazione e limitazione della finalità.** Si trattano i dati necessari allo scopo dichiarato, e non si riusano per finalità diverse senza una nuova valutazione.
- **Dove avviene l'elaborazione.** Trasferire dati a un servizio esterno è un trattamento, e va valutato prima.
- **Anonimizzazione e pseudonimizzazione non sono la stessa cosa:** la pseudonimizzazione da sola non esclude il rischio reidentificazione.

La conseguenza pratica più frequente è sull'architettura: molte scelte tecniche ragionevoli diventano impraticabili se implicano che il dato esca dall'infrastruttura in cui è stato raccolto.

Ruolo del modello nella decisione clinica



- Il modello **propone**, il clinico decide.
- Il clinico dispone di informazioni che il modello non ha: esame obiettivo, anamnesi narrativa, contesto.
- **La soglia è una scelta clinica**, perché dichiara un rapporto fra costi che riguarda i pazienti.
- La responsabilità professionale non si trasferisce al software.



Riproducibilità e versionamento

- **Il preprocessing fa parte del modello.** Imputazione, codifiche, standardizzazione e costruzione delle variabili derivate vanno versionate insieme ai pesi e applicate identiche in produzione.
- **La calibrazione è un artefatto inseparabile.** Va versionata con il modello su cui è stata stimata, e con l'indicazione della popolazione su cui è stata calcolata.
- **I dati vanno versionati come il codice:** definizione della coorte, criteri di inclusione, data di estrazione.
- **I random seed non bastano.** Versioni delle librerie, ordine delle operazioni e parallelismo possono cambiare il risultato.

Un modello clinico deve poter essere ricostruito a distanza di tempo, perché è la condizione perché il suo output possa essere giustificato.