



---

## MODULO 2

# Modelli predittivi su dati tabellari clinici



# Obiettivi e struttura della lezione



---

# Argomenti della lezione

- **I dati:** valori mancanti strutturali, feature engineering su valori di laboratorio, feature selection e sua stabilità.
- **I modelli:** dalla regressione logistica ai modelli additivi, al gradient boosting, alle reti tabellari e ai modelli fondazionali.
- **La spiegazione:** interpretabilità globale e locale, metodi intrinseci e post-hoc, e i loro limiti documentati.
- **La valutazione:** metriche su classi sbilanciate, calibrazione delle probabilità, quantificazione dell'incertezza, protocolli di validazione clinica.
- **La produzione:** monitoraggio, aggiornamento, e i vincoli normativi che decidono dove il modello può girare.

**Il filo è uno solo: seguire il numero prodotto dal modello dal dato che entra alla decisione che esce, e vedere in ciascun punto che cosa lo rende inaffidabile.**



---

PASSO 1

# Predizione su dati tabellari clinici

# Definizione del problema

**Dato un insieme di variabili anagrafiche e di risultati di analisi di laboratorio riferiti a un singolo paziente in un singolo momento, stimare la probabilità che una determinata condizione clinica sia presente.**

- l'uscita desiderata è un suggerimento per un clinico
- le variabili disponibili **possono cambiare da paziente a paziente** (missing data)
- la condizione da individuare è tipicamente **rara** nella popolazione osservata

# Caratteristiche dei dati tabellari

## Immagini, testo, segnali

---

- le componenti sono omogenee e confrontabili fra loro
- spesso esiste una struttura locale (feature spazialmente o temporalmente vicini sono correlati)
- l'ordine delle componenti è informativo
- i dataset di riferimento sono grandi

## Dati tabellari

---

- ogni attributo ha unità, scala e semantica proprie
- nessuna struttura locale: le colonne non hanno correlazioni note a priori
- l'ordine delle colonne è arbitrario
- i dataset clinici sono tipicamente piccoli

**Da queste differenze discende il fatto empirico che sui dati tabellari gli alberi di decisione restano competitivi con le architetture neurali, che invece dominano altrove.**



# Struttura di un record clinico

| GRUPPO                      | ESEMPI                                   | TIPO              | DISPONIBILITÀ    |
|-----------------------------|------------------------------------------|-------------------|------------------|
| anagrafica                  | età, sesso                               | continua, binaria | sempre presente  |
| anamnesi                    | interventi pregressi, gravidanza         | binaria           | sempre presente  |
| terapie in corso            | farmaco sostitutivo, farmaco soppressivo | binaria           | sempre presente  |
| sospetti del clinico        | quesito diagnostico posto in richiesta   | binaria           | sempre presente  |
| <b>esami di laboratorio</b> | <b>valori dosati nel siero</b>           | <b>continua</b>   | <b>variabile</b> |
| indicatori di esecuzione    | l'esame è stato eseguito o no            | binaria           | sempre presente  |
| provenienza                 | struttura che ha inviato il paziente     | categorica        | sempre presente  |

Le feature provenienti da esami di laboratorio sono tipicamente molto informative, ma la loro presenza è variabile: la gestione dei missing data diventa cruciale.




---

# Domini di applicazione

- **Diagnosi e stratificazione del rischio** a partire da esami di routine: individuare i pazienti da approfondire.
- **Prognosi**: probabilità di un evento entro un orizzonte temporale definito.
- **Triage e prioritizzazione** in contesti a risorse limitate.
- **Predizione di riammissione o di complicanza** dopo un ricovero.
- **Medicina di laboratorio**: controllo di plausibilità dei referti e individuazione di risultati anomali.

**In tutti i casi il modello non sostituisce una decisione (che resta in capo al clinico), ma la supporta.**

# Ordinamento vs probabilità



- Il primo caso richiede solo che l'ordinamento sia corretto. La scala dei valori è irrilevante.
- Il secondo caso richiede che **l'output sia interpretabile** (e.g. probabilità).

# Discriminazione, calibrazione, utilità clinica

## Discriminazione

«il modello distingue casi positivi e negativi?»

---

C-statistic · curva precision-recall

## Calibrazione

«la predizione è interpretabile?»

---

reliability diagram · pendenza e intercetta

## Utilità clinica

«l'output aiuta nelle decisioni cliniche?»

---

curva di decisione · net benefit

# Il caso in esame

3.772

pazienti

29

variabili

6 %

prevalenza

- **UCI Thyroid Disease**: predizione di una condizione tiroidea da anagrafica, anamnesi ed esami di laboratorio.
- **Sei esami somministrabili**, ciascuno accompagnato da un flag che indica se è stato eseguito. Il dataset rende quindi **esplicita, riga per riga**, i missing data.
- Un esame non è stato somministrato in **nessun** paziente della raccolta: un caso limite utile.
- Le classi sono fortemente sbilanciate, in rapporto di circa **quindici a uno**.




---

PASSO 1.5

# Criticità del problema in esame

# Valori mancanti strutturali



- Non tutti i pazienti ricevono lo stesso insieme di analisi.
- L'assenza di alcune feature è **un risultato naturale** del processo che "genera" i dati (i flussi di lavoro clinici).
- Lo stesso vale in inferenza: il modello in produzione riceverà record incompleti.

**Un modello addestrato sui soli casi completi è tarato su una popolazione che in inferenza non esiste.**



# Meccanismi all'origine dei dati mancanti

Sia  $X$  il dato completo e  $M$  la maschera che indica quali valori sono osservati.

| MECCANISMO                                      | DA COSA DIPENDE $M$                           | ESEMPIO CLINICO                                                        |
|-------------------------------------------------|-----------------------------------------------|------------------------------------------------------------------------|
| <b>MCAR</b> <i>missing completely at random</i> | da niente                                     | provetta rotta in trasporto                                            |
| <b>MAR</b> <i>missing at random</i>             | solo dalle parti <b>osservate</b> di $X$      | il panel di esami di laboratorio dipende dal reparto, che è registrato |
| <b>MNAR</b> <i>missing not at random</i>        | anche dalle parti <b>non osservate</b> di $X$ | l'esame non è stato chiesto perché il paziente appariva sano           |
| self-masking                                    | dal valore <b>stesso</b> che manca            | caso particolare di MNAR, il più frequente in clinica                  |

La distinzione non è verificabile dai dati. Da un dataset non si può dimostrare che il meccanismo sia MAR: è un'ipotesi sul processo clinico.

Terminologia introdotta da Rubin (1976); la trattazione moderna in predizione è in Josse et al., *On the consistency of supervised learning with missing values*, Statistical Papers 2024.


# Missingness informativa e self-masking

La missingness è informativa quando la maschera  $M$  porta informazione sull'esito che i valori osservati non contengono già.

- il predittore ottimo dipende **dalla maschera oltre che dai valori**
- i pattern di missingness possibili sono  $2^p$ : costruire un metodo che li tratta separatamente è infattibile
- l'informazione contenuta nella maschera riguarda **il comportamento del clinico**

**Conseguenza in production: la maschera di missingness dipende dal protocollo clinico, che è soggetto a drift.**

# Sbilanciamento delle classi



- Nei problemi diagnostici la condizione da individuare è tipicamente presente in una frazione piccola della popolazione osservata.
- **L'accuratezza diventa inutilizzabile.**
- L'addestramento risente della scarsità: la loss function è dominata dalla classe maggioritaria.
- Il vincolo statistico è il **numero di eventi positivi**, che determina l'incertezza su ogni metrica.

# Costo asimmetrico degli errori

## Falso negativo

- una condizione presente non viene segnalata
- il caso non viene approfondito
- il costo è clinico (ritardo nel trattamento) e differito nel tempo
- spesso non viene mai osservato

## Falso positivo

- un paziente sano viene inviato ad approfondimento
- costo economico, di tempo e di ansia
- il costo è immediato e misurabile
- viene sempre osservato

**Il rapporto fra i due costi è definito dalle soglie scelte in fase di calibrazione dei modelli, ed è dettato anche da considerazioni cliniche.**

# Data leakage nei dati clinici

- **Definizione.** Una variabile disponibile in addestramento che in produzione non esiste, o che contiene informazione ottenuta a valle del fenomeno da predire.
- **Variabili post-evento:** terapie iniziate dopo la diagnosi, codici di dimissione, successivi accertamenti.
- **Variabili di processo:** reparto di provenienza, tipo di richiesta, urgenza. Codificano il **sospetto già formulato dal clinico**.
- **La maschera di missingness stessa**, quando l'esame è stato prescritto proprio perché esisteva un sospetto clinico.

**In molti casi la mitigazione dei leakage può avvenire solo tramite ricostruzione del flusso di raccolta dei dati, e valutazione delle singole variabili con supporto di esperti di dominio.**

---

# Numerosità limitata degli eventi

- Nei modelli di predizione clinica il campione utile non si conta in righe: si conta in **eventi**, cioè casi della classe minoritaria.
- Da lì dipende l'incertezza su ogni stima: metriche, coefficienti, forma delle funzioni apprese.
- Con poche decine di eventi, l'intervallo di confidenza su una metrica può essere più largo della differenza fra due modelli che si vogliono confrontare.
- Le regole empiriche storiche — dieci eventi per variabile, cento eventi per una validazione — sono state mostrate inaffidabili e sostituite da calcoli mirati.

**Il dimensionamento del campione chiude il Passo 4, ed è la stessa questione vista dal lato della progettazione anziché da quello della misura.**



---

PASSO 2

# Costruzione e preprocessing dei dati



# Tipi di variabile e loro trattamento

| TIPO                     | ESEMPI                                 | TRATTAMENTO                                                                |
|--------------------------|----------------------------------------|----------------------------------------------------------------------------|
| continua misurata        | valore somministrato di un farmaco     | standardizzazione, oppure nessun preprocessing (se il modello è ad albero) |
| continua derivata        | rapporto fra due valori di laboratorio | ricalcolata, se necessario                                                 |
| categorica ordinale      | classe di severità                     | codifica che conserva l'ordine                                             |
| categorica nominale      | struttura di provenienza               | one-hot                                                                    |
| binaria                  | terapia in corso, sesso                | nessuno                                                                    |
| indicatore di esecuzione | l'esame è stato eseguito               | nessuno (la maschera di missingness)                                       |

**Le variabili derivate vanno ricalcolate dopo l'imputazione, non imputate: un rapporto imputato non è coerente con i suoi ingressi e introduce contraddizioni che il modello impara.**

# Trattamento dei valori mancanti: panoramica

| FAMIGLIA                    | ESEMPI                       | CHE COSA ASSUME                                 | COSTO                             |
|-----------------------------|------------------------------|-------------------------------------------------|-----------------------------------|
| cancellazione dei casi      | complete-case analysis       | che i casi completi siano rappresentativi       | perdita di dati, distorsione      |
| imputazione con costante    | media, mediana, valore fisso | che il modello a valle sia flessibile           | nullo                             |
| imputazione multipla        | MICE, imputazione iterativa  | un modello per colonna a partire dalle altre    | alto, e va replicata in inferenza |
| basata sui vicini           | kNN imputer                  | che la somiglianza sulle colonne presenti basti | alto in inferenza                 |
| indicatore di missingness   | colonna binaria aggiuntiva   | che l'assenza porti informazione                | nullo, ma fragile                 |
| gestione nativa nel modello | alberi con MIA               | niente: l'assenza è una direzione dello split   | nullo                             |
| modelli per pattern         | pattern submodels            | un modello per ogni pattern osservato           | esponenziale                      |
| architetture dedicate       | NeuMiss                      | una forma parametrica del predittore ottimo     | implementativo                    |

**Nessuna riga di questa tabella è «la soluzione corretta». La scelta dipende dal meccanismo assunto e dal costo che si può sostenere in inferenza, non da un confronto di accuratezza.**

# Indicatori di missingness

- **Costruzione.** Per ogni variabile che può mancare si aggiunge una colonna binaria che dice se il valore è presente. Il modello riceve valori e maschera insieme.
- **Quando aiuta.** Quando la missingness è informativa: l'indicatore è il canale attraverso cui l'informazione arriva al modello.
- **Quando è ridondante.** Quando il modello gestisce già i valori assenti nativamente: l'indicatore duplica un'informazione che il modello ha già.
- **Perché è fragile.** L'indicatore codifica una **prassi operativa**. Se il protocollo di prescrizione cambia, la regola appresa diventa falsa, e le metriche calcolate sul vecchio test set restano buone.

**In letteratura clinica il bilancio è controverso: alcuni studi riportano un guadagno in scenari MNAR, altri nessuna differenza, e tutti segnalano il rischio di generalizzazione fra contesti diversi.**

# Alberi con MIA


A ogni split, l'albero decide dove mandare i record in cui quella variabile manca. Ha tre possibilità.



- La scelta è **appresa**: vince quella che riduce di più la funzione di costo.
- Vale split per split, quindi la stessa variabile può mandare gli assenti a sinistra in un nodo e a destra in un altro.

**MIA — Missing Incorporated in Attribute.** L'albero non «gestisce» i valori assenti: li usa come informazione.

# Valori mancanti in addestramento e in inferenza



- rifiutare la **predizione** e delegare a un operatore
- **imputare**, con le statistiche del training set
- usare un **modello addestrato sul sottoinsieme** di colonne disponibili
- gestione nativa del modello

L'ultima opzione ha una criticità: il contributo associato all'assenza di una variabile è stimato sui casi in cui quella variabile mancava in addestramento: se sono pochissimi, il parametro è di fatto non addestrato.




---

# Feature engineering su dati di laboratorio

- **Indicatori clinici noti in letteratura.** Molti indici clinici consolidati sono ottenuti con formule sui valori misurati. Per individuarli è necessaria una ricerca in letteratura o il supporto di un esperto di dominio.
- **Differenze rispetto a un riferimento.** Distanza dal limite superiore o inferiore dell'intervallo di normalità, in valore assoluto o in multipli dell'ampiezza.
- **Fasce di severità note.** Hanno il vantaggio di rendere il modello più interpretabile per chi lo userà.
- **Aggregazioni.** Numero di misure di laboratorio fuori range, numero di misure complessive.

**Su dati clinici, a causa della loro scarsità, la conoscenza di dominio risulta particolarmente utile e spesso investire in questo aspetto garantisce un ritorno maggiore.**

# Range di riferimento



- Il clinico legge il referto in tre categorie: **sotto, dentro, sopra** l'intervallo.
- Il modello vede solo un numero su una scala continua: quell'intervallo non lo conosce.
- L'intervallo **cambia con età e sesso**: lo stesso valore non significa la stessa cosa in due pazienti.
- Passare al modello **la posizione rispetto all'intervallo**, e non solo il valore, gli dà l'informazione che il clinico usa.

# Preprocessing e prevenzione del leakage

- **Le statistiche si calcolano sul solo training set.** Medie, deviazioni standard, valori di imputazione, quantili, codifiche delle categoriche.
- **La selezione delle variabili sta dentro la cross-validation**, non prima. Selezionare su tutto il dataset e poi validare produce una stima ottimistica.
- **Lo split rispetta la struttura dei dati.** Se un paziente compare più volte, tutte le sue righe stanno dalla stessa parte. Se i dati vengono da centri diversi, lo split casuale non misura la generalizzazione che interessa.
- **Il preprocessing fa parte del modello** e va versionato con i pesi. In produzione va applicato identico, nella stessa sequenza.



---

PASSO 3

# Dalla baseline ai modelli avanzati

# Baseline: regressione logistica

Il modello di riferimento storico per il rischio clinico. Un coefficiente per variabile, e il logit della probabilità come somma dei contributi.

$$\text{logit } p(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

- Ogni coefficiente ha un'interpretazione diretta: **odds ratio** per unità di variabile.
- È la forma di molti punteggi di rischio in uso clinico.
- **Il limite.** Assume che l'effetto di ogni variabile sul logit sia lineare: sui valori di laboratorio il rischio sale a entrambe le code, e una retta non può rappresentarlo.

**Rappresentando molti modelli realmente in uso, costituisce un ottimo punto di partenza. Il passo successivo abbandona la linearità e tiene l'additività.**

# GAM — Generalized Additive Models

I **GAM** sostituiscono ogni coefficiente con una funzione stimata dai dati. La forma della dipendenza è appresa.

LINEARE  $\text{logit } p(x) = \beta_0 + \sum_j \beta_j x_j$

GAM  $\text{logit } p(x) = \beta_0 + \sum_j f_j(x_j)$


- Ogni  $f_j$  è una **shape function**: una relazione che si può valorizzare su ogni record.
- Si perde la linearità, si conserva la **somma**: il contributo di ogni variabile resta separabile dagli altri.
- L'additività rendere il modello interpretabile.

# Stima delle shape function


Ogni curva viene **stimata dai dati**, una variabile alla volta.



$f_1$   
età



$f_2$   
primo analita



$f_3$   
secondo analita

- Non serve dire in anticipo dove sono le soglie: le trova la stima.
- Il risultato è una curva per variabile, che si guarda e si discute con il clinico.

**È la stessa lettura del referto: rischio in funzione del valore, un grafico per esame.**

# Interazioni: modelli GA2M


$$\text{logit } p(x) = \beta_0 + \sum_j f_j(x_j) + \sum_{(j,k)} f_{jk}(x_j, x_k)$$



- Il modello additivo puro non rappresenta le interazioni: l'effetto di una variabile non può dipendere dal valore di un'altra. Il **GA2M** aggiunge termini su coppie di variabili, selezionate automaticamente durante l'addestramento.
- Ogni  $f_{jk}$  è una **funzione di due variabili**,  $R^2 \rightarrow R$ , stimata a gradini su una griglia di bin: per questo si disegna come heatmap.

Il numero di coppie ammesse è un iperparametro, e i valori predefiniti sono generosi: la leggibilità è reale sulle curve singole, sulle coppie è nominale.


# Explainable Boosting Machine



- È un **GA2M addestrato con boosting ciclico**: prima i termini univariati, poi le coppie selezionate.
- Il passo è deliberatamente piccolo e i giri sono molti, così che l'ordine delle variabili non conti.
- Ogni variabile riceve una **categoria dedicata per i valori assenti**, con un contributo proprio, stimata come gli altri.
- Il costo di addestramento è di uno o due ordini di grandezza superiore a quello di un gradient boosting non vincolato sullo stesso dato.

**Implementato nella libreria `interpret`, con licenza MIT.**

# Non identificabilità dei modelli additivi



- Una costante spostata da una componente all'altra **non cambia la predizione**. Serve un vincolo aggiuntivo per rendere la scomposizione unica.
- Con **variabili correlate** il problema si amplifica.
- Se si cerca di interpretare le shape function, due modelli equivalenti in predizione possono suggerire letture cliniche diverse.



---

# Decision tree e random forest

- **L'albero singolo** partiziona lo spazio con soglie su singole variabili. È leggibile finché resta poco profondo, e instabile: piccole variazioni nei dati cambiano la struttura.
- **Il random forest** media molti alberi addestrati su resampling e sottoinsiemi di variabili. Riduce la varianza, perde l'interpretabilità.
- **Pregi pratici:** pochi iperparametri, addestramento rapido, gestione implicita dei valori assenti, e nessuna necessità di standardizzare.

# Gradient boosting



- Ogni albero è addestrato a correggere l'errore dei precedenti.
- Gli alberi sono **deliberatamente poco profondi** e il learning rate è piccolo.
- Gli iperparametri principali sono tre: numero di alberi, profondità, learning rate. Si influenzano a vicenda.
- La regolarizzazione avviene per subsampling di righe e colonne, e per penalizzazione sulla dimensione degli alberi.

**Baseline di riferimento su dati tabellari.**

# XGBoost, LightGBM, CatBoost

## XGBoost

### PRINCIPIO

Crescita **per livello**: l'albero si espande un piano alla volta.

### PRO

Comportamento prevedibile, la più collaudata, ottimo supporto ai vincoli di monotonicità.

### CONTRO

Le variabili categoriche vanno codificate a mano.

## LightGBM

### PRINCIPIO

Crescita **per foglia**: espande la foglia che promette il guadagno maggiore.

### PRO

La più rapida sui dataset grandi; gestisce le categoriche nativamente.

### CONTRO

Su pochi dati va più facilmente in overfitting.

## CatBoost

### PRINCIPIO

Alberi **simmetrici** e **target encoding ordinato** per le categoriche.

### PRO


Robusto sui dataset piccoli, spesso il meglio calibrato.

### CONTRO

Più lento; i valori assenti finiscono sempre allo stesso estremo.

Le differenze di accuratezza fra i tre sono tipicamente entro l'incertezza della misura. Si scelgono per come trattano categoriche, valori assenti e campioni piccoli.

# Vincoli di monotonicità



- **Quando.** Quando si sa già che l'effetto va in una sola direzione: più alto il valore, più alto il rischio.
- **Perché.** Dove i dati sono pochi il modello disegna avvallamenti che non esistono. Una curva che scende dove non dovrebbe è un errore evidente per chi conosce il dominio, e fa perdere fiducia in tutto il modello.
- **Come.** Si dichiara il vincolo prima dell'addestramento: durante la costruzione degli alberi vengono scartati gli split che lo violerebbero.
- **Quanto costa.** Quasi niente in accuratezza: si sta aggiungendo un'informazione vera, non limitando il modello.

# Modelli bayesiani

Invece di un solo valore per ogni parametro, si stima una **distribuzione** di valori possibili.

$$p(\theta \mid \text{dati}) \propto p(\text{dati} \mid \theta) \cdot p(\theta)$$

a sinistra ciò che si conclude sui parametri, poi quanto i dati sono compatibili con essi, poi ciò che si assumeva prima di vederli.

## vantaggi

- Dà un'incertezza **sul modello**, non solo sulla singola predizione.
- Permette di inserire conoscenza di dominio come distribuzione a priori.
- Regge meglio quando i dati sono pochi.

## svantaggi

- Il costo di calcolo cresce rapidamente con il numero di osservazioni.
- Su dati tabellari **non è competitivo** con il gradient boosting.
- Le distribuzioni a priori sono una scelta in più da giustificare.

### UN ESEMPIO

**Regressione logistica bayesiana.** Stessa forma della baseline, ma ogni coefficiente  $\beta_j$  è una distribuzione invece di un numero. Il risultato non è «l'effetto dell'analita A è +0,4», è «è +0,4, plausibilmente fra +0,1 e +0,7». Su un paziente si ottiene così **un intervallo sulla probabilità predetta**, non un solo valore.

# Modelli additivi neurali

Stessa struttura additiva dei GAM, ma ogni shape function è una **piccola rete neurale**.

$$\text{logit } p(x) = \beta_0 + \sum_j \text{rete}_j(x_j)$$

una rete per variabile, addestrate insieme · varianti principali: NAM, NODE-GAM, GAMI-Net

## vantaggi

- Sono differenziabili, quindi si addestrano insieme al resto di una pipeline.
- Alcune varianti danno un'incertezza sulle singole curve.
- Su dataset grandi e con molte interazioni vanno meglio degli additivi ad albero.

## svantaggi

- Servono molti dati: su tabellari piccoli non battono gli alberi.
- Addestramento più lento e più iperparametri da scegliere.

**Utili quando la tabella va addestrata insieme a un'altra modalità, o quando serve un modello differenziabile end-to-end. Ma richiede molti dati.**



# Modelli ibridi

| FORMA                           | MECCANISMO                                                                                  | VANTAGGIO                                                                 |
|---------------------------------|---------------------------------------------------------------------------------------------|---------------------------------------------------------------------------|
| interpretabile con delega       | il modello leggibile decide dove è competente, il resto va a un modello non vincolato       | è noto <b>quali</b> casi hanno ricevuto una decisione spiegabile          |
| additivo con correzione residua | un modello additivo cattura la parte principale, un boosting impara il residuo              | completamente spiegabile, se si accettano i due layer di interpretabilità |
| forma additiva estratta         | si addestra un boosting con vincoli di interazione e lo si scompone in componenti leggibili | leggibilità a posteriori senza rinunciare all'addestramento non vincolato |
| distillazione                   | un modello complesso genera le etichette con cui si addestra un modello semplice            | modello distillato leggibile e leggero                                    |

La prima forma è la più adatta a un contesto clinico, perché rende esplicito il sottoinsieme di pazienti su cui il sistema è in grado di motivare la propria uscita.



# Metodi non trattati (review, primo passo)

| METODO                              | AMBITO                                                   | RIFERIMENTO                               |
|-------------------------------------|----------------------------------------------------------|-------------------------------------------|
| NeuMiss                             | architettura per il predittore ottimo con valori assenti | Le Morvan et al., NeurIPS 2020            |
| pattern submodels                   | un modello per ciascun pattern di missingness            | letteratura statistica su dati incompleti |
| MICE, regole di Rubin               | imputazione multipla con inferenza corretta              | Rubin 1987; van Buuren 2018               |
| missForest                          | imputazione iterativa con random forest                  | Stekhoven, Bühlmann 2012                  |
| ProtoNAM, Neural Basis Models       | varianti di modelli additivi neurali                     | letteratura 2023–2025                     |
| analisi di sopravvivenza            | esito con tempo all'evento e censura                     | Cox 1972 e successivi                     |
| modelli causali                     | effetto di un intervento, non predizione                 | letteratura su inferenza causale          |
| fairness e disparità di sottogruppo | equità delle prestazioni fra popolazioni                 | letteratura dedicata                      |



---

PASSO 3.5

# Interpretabilità



---

# Interpretabilità globale e locale

## Globale

---


- descrive il comportamento del modello nel suo insieme
- quali variabili hanno maggior impatto, e in quale direzione
- serve alla validazione, alla documentazione, al confronto con la conoscenza di dominio
- non dipende dal singolo record

## Locale

---

- spiega **una** predizione
- serve durante l'uso clinico, davanti a un caso concreto
- varia da caso a caso, e la sua stabilità va valutata

# Lettura di una shape function



- L'asse verticale è il **contributo al logit**. Sopra lo zero la variabile aumenta il rischio, sotto lo riduce.
- La **pendenza** dice dove il rischio cambia più in fretta; i tratti piatti sono intervalli in cui il valore non fa differenza.
- L'istogramma dà il **numero di casi per intervallo**. Dove è basso — tipicamente le code — la curva è stimata su pochi dati.

La curva è la spiegazione: non c'è un secondo modello che stima cosa il primo ha fatto.

---

# Metodi post-hoc

Si applicano a modelli già addestrati, senza toccarli: si osserva **come si comporta** cambiando gli ingressi e osservando le uscite (black box).

- **Il vantaggio.** Si applicano a qualunque modello, anche a uno che non è stato progettato per essere leggibile.
- **Il limite.** Producono una **stima** del comportamento del modello, non il comportamento stesso (stima soggetta a errori).

---

## I TRE CHE VEDIAMO

- 1 **Permutation importance** — quanto il modello stimatore si appoggia a una variabile
- 2 **Partial dependence** — l'effetto medio di una variabile sulle predizioni
- 3 **SHAP** — il contributo di ogni variabile a una singola predizione

Esistono altri metodi — LIME, controfattuali, ICE — che rispondono a domande simili con gli stessi limiti.

# Permutation e partial dependence


|     |     |     |              |     |     |     |
|-----|-----|-----|--------------|-----|-----|-----|
| ... | 4,2 | ... | shuffle<br>→ | ... | 9,1 | ... |
| ... | 1,8 | ... |              | ... | 3,0 | ... |
| ... | 9,1 | ... |              | ... | 1,8 | ... |

Gli stessi valori, assegnati ad altri pazienti: la colonna resta plausibile ma **perde ogni legame con l'esito**.

- **Permutation importance.** Si rimescolano i valori di una colonna fra le righe e si misura di quanto peggiora la metrica. Se peggiora molto, il modello si appoggiava a quella variabile.
- Se due variabili sono fortemente correlate, rimescolandone una il modello potrebbe recuperare l'informazione dall'altra: la metrica non cala e sembrano entrambe inutili.
- **Partial dependence.** Si fissa una variabile a un valore, si predice su tutti i pazienti, si fa la media; ripetendo su una griglia di valori si ottiene la curva dell'effetto medio. Problema: si costruiscono esempi out-of-distribution.

# Valori di Shapley e SHAP


Il modello predice **0,36** per questo paziente e in media **0,06**: SHAP **distribuisce la differenza** fra le variabili. Ogni barra parte dove finisce la precedente.



- Il contributo è quanto la variabile **sposta la predizione** quando viene aggiunta alle altre, mediato su **tutti gli ordini** di aggiunta possibili. Sommati, ricostruiscono esattamente lo scarto dalla media.
- Il calcolo esatto costa  $2^p$  valutazioni. Sugli alberi esiste **TreeSHAP**, che lo risolve in tempo polinomiale: è la ragione per cui SHAP è diventato lo standard sui dati tabellari.
- TreeSHAP ha però **due varianti** — *conditional* e *interventional* — che simulano in modo diverso l'assenza di una variabile e danno risultati diversi sullo stesso modello. La libreria sceglie in base agli argomenti che le si passano: va dichiarato quale si è usata.

**Le proprietà valgono per i valori esatti; con l'approssimazione valgono in modo approssimato.**

# Disaccordo fra metodi di spiegazione



- Metodi diversi applicati allo stesso modello producono ordinamenti diversi, e la discordanza cresce con la correlazione fra le variabili.
- **Non esiste una ground truth:** l'importanza reale di una variabile non è una quantità osservabile, quindi non si può stabilire quale metodo sbaglia.
- Il fenomeno è documentato in modo sistematico e riguarda anche coppie di metodi che misurano nominalmente la stessa cosa.

**Conseguenza operativa: l'attribuzione serve a generare ipotesi da verificare con un esperimento o con la conoscenza di dominio, mai come prova a sostegno di una conclusione.**



# Destinatari della spiegazione

| DESTINATARIO    | DOMANDA                                          | FORMA ADATTA                                    | QUANDO SERVE               |
|-----------------|--------------------------------------------------|-------------------------------------------------|----------------------------|
| clinico         | «posso fidarmi della predizione su questo caso?» | contributi del singolo caso, in unità cliniche  | al momento della decisione |
| paziente        | «perché sono stato segnalato?»                   | poche frasi in linguaggio naturale              | su richiesta               |
| ente regolatore | «quali variabili sono state usate?»              | descrizione globale, documentazione del modello | in fase di approvazione    |
| sviluppatore    | «dove sbaglia?»                                  | analisi degli errori, casi limite, stabilità    | in fase di sviluppo        |



---

PASSO 4

# Valutazione: metriche, calibrazione, incertezza



# Metriche di classificazione binaria



| METRICA     | INTERPRETAZIONE                                  | QUANDO È FUORVIANTE                                                |
|-------------|--------------------------------------------------|--------------------------------------------------------------------|
| accuratezza | frazione di predizioni corrette                  | classi sbilanciate: la si massimizza rispondendo sempre «negativo» |
| recall      | quota di positivi individuati                    | da sola non dice quanti falsi positivi costa                       |
| specificità | quota di negativi riconosciuti                   | a bassa prevalenza è quasi sempre altissima                        |
| precision   | quota di segnalazioni corrette                   | dipende dalla prevalenza, quindi non trasferisce fra popolazioni   |
| F1          | media armonica di precision e recall             | pesa recall e precision in modo simmetrico                         |
| AUROC       | probabilità di ordinare correttamente una coppia | non dice niente sulla calibrazione                                 |

# Metriche su classi sbilanciate

- **L'accuracy non è informativa.** Con prevalenza al 6 % un classificatore che predice sempre la classe negativa raggiunge il 94 %.
- **La baseline della curva precision-recall è la prevalenza**, non 0,5. Un'average precision di 0,30 con prevalenza 0,06 corrisponde a un fattore cinque sul caso.
- **La precision dipende dalla prevalenza**, quindi non si trasferisce fra popolazioni: a soglia invariata, lo stesso modello ha precision diversa in un contesto con prevalenza diversa.
- **Sensibilità e specificità si trasferiscono**, essendo condizionate alla classe vera. Per questo la letteratura clinica le riporta come descrittori primari.

**Un valore di average precision va sempre riportato insieme alla prevalenza del campione su cui è calcolato.**

# Curva ROC e curva precision-recall



- **La ROC** divide i falsi positivi per tutti i negativi: a bassa prevalenza sono moltissimi.
- **La precision-recall** li divide per le segnalazioni fatte: lo stesso peggioramento si vede.


Non è che una curva sia giusta e l'altra sbagliata: rispondono a due domande. A bassa prevalenza, l'impressione che danno è molto diversa.

# Scelta della soglia operativa

- **Il modello restituisce un punteggio continuo;** la decisione binaria richiede una soglia, che non fa parte dell'addestramento ed è una scelta a valle.
- **Precision a recall fissato.** È la forma in cui il requisito arriva dal clinico: fissata la sensibilità richiesta, si misura il volume di falsi positivi che ne consegue.
- **Massimizzare F1 è una scelta implicita.** Fissa un rapporto fra i costi dei due errori uguale per ogni contesto, senza dichiararlo.
- **La soglia è legata alla popolazione.** A prevalenza diversa, la stessa soglia produce un punto di lavoro diverso, e va rivista.

**La soglia si deriva dal rapporto fra i costi dei due errori, che si formalizza con gli strumenti di utilità clinica alla fine del passo.**

# Intervalli di confidenza sulle metriche



- La metrica calcolata su un test set è una **stima**, e dipende da quello specifico test set.
- Il **bootstrap** — resampling con reimmissione delle righe del test set — dà un intervallo di confidenza attorno alla stima.
- L'intervallo dice **se il confronto è possibile**. Se gli intervalli dei due modelli si sovrappongono, il confronto è poco informativo.



# Confronto fra due modelli


| APPROCCIO                           | PROCEDURA                                                                     | QUANDO USARLO                                                                                    |
|-------------------------------------|-------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| confronto di intervalli separati    | si guardano i due intervalli e si controlla se si sovrappongono               | <b>da evitare:</b> ignora che i modelli sono valutati sugli stessi casi ed è troppo conservativo |
| bootstrap sulla differenza appaiata | a ogni resampling si calcolano entrambe le metriche e si prende la differenza | confronto fra metriche continue sullo stesso test set                                            |
| test di McNemar                     | tabella delle discordanze fra le due decisioni binarie                        | confronto fra decisioni a soglia fissata                                                         |
| validazione ripetuta                | si ripete l'intero protocollo su split diversi                                | quando il test set è piccolo e si può ricampionare l'addestramento                               |

# Calibrazione: definizione

Un modello è calibrato quando, fra tutti i casi ai quali assegna probabilità  $p$ , la frazione di positivi osservata è  $p$ . Questo deve valere per ogni valore di  $p$ .

- **in media** — la media delle probabilità predette uguaglia la prevalenza osservata
- **debole** — pendenza di calibrazione pari a 1 e intercetta pari a 0
- **moderata** — la definizione qui sopra, per ogni valore di  $p$
- **forte** — la stessa proprietà **dentro ogni sottogruppo** della popolazione

# Reliability diagram



- Le predizioni si raggruppano in **bin**; per ciascuno si confronta la probabilità media predetta con la frazione di positivi osservata.
- La **diagonale** è la calibrazione perfetta. I punti sotto la diagonale indicano un modello che sovrastima il rischio.
- Il **numero e il tipo di bin** cambiano l'aspetto del grafico, e non esiste una scelta neutra.
- A prevalenza bassa quasi tutte le predizioni cadono nei primi bin, e il resto del grafico è stimato su pochissimi casi.

Per questo la letteratura clinica non si affida all'ispezione visiva, ma a due statistiche che non dipendono dai bin.

# Pendenza e intercetta di calibrazione

Si adatta una regressione logistica che ha come unica variabile il logit delle probabilità predette, e come esito l'evento osservato.


calibrazione.txt

```
logit p_oss = a + b * logit p_pred
b = 1, a = 0    -> calibrato
b < 1           -> predizioni troppo estreme
b > 1           -> predizioni troppo compresse verso il centro
a != 0          -> errore sistematico di livello: prevalenza sbagliata
```


- **Non dipendono dai bin**, a differenza del reliability diagram.
- I due parametri separano due difetti diversi: b riguarda la dispersione, a il livello.
- **Calibrazione in the large**: si fissa  $b = 1$  e si stima il solo a. È la forma che interessa quando cambia solo la prevalenza.

**Sono il linguaggio standard nella letteratura sui modelli di predizione clinica, e vanno riportati entrambi.**

# Proprietà della ricalibrazione




probabilità: si spostano



ordinamento: identico

- Tutti i metodi di ricalibrazione sono **trasformazioni monotone** del punteggio.
- Ne discende che **l'ordinamento dei casi non cambia**: l'AUROC e l'area sotto la curva precision-recall restano invariate.
- Se il problema è la scelta di **chi approfondire per primo**, la ricalibrazione non serve a niente.
- Se il problema è **usare il valore come una probabilità** — confrontarlo con una soglia, comunicarlo a un paziente, combinarlo con un costo — allora è indispensabile.

# Shift di prevalenza



- È la forma di shift più comune in ambito clinico: cambia **quanto è frequente** la condizione, non **come si manifesta**.
- La relazione fra variabili ed esito resta la stessa, quindi il modello continua a ordinare correttamente i pazienti.
- Le probabilità però sono calcolate rispetto alla vecchia prevalenza, quindi risultano sistematicamente troppo basse o troppo alte.
- La soglia scelta sulla popolazione di sviluppo produce, sulla nuova, un punto di lavoro diverso da quello previsto.

Si diagnostica con l'intercetta di calibrazione e con il confronto fra probabilità media predetta e prevalenza osservata. Esistono tecniche di correzione dello shift di prevalenza.

# ■ Incertezza aleatoria ed epistemica

## Aleatoria

---

- rumore intrinseco del fenomeno
- due pazienti identici sulle variabili disponibili possono avere esiti diversi
- **non si riduce** raccogliendo più dati
- si riduce solo misurando variabili nuove

## Epistemica

---

- ignoranza del modello
- alta dove i dati di addestramento sono radi o assenti
- **si riduce** raccogliendo più dati

La distinzione è operativa, in quanto solo l'incertezza epistemica giustifica la raccolta di nuovi dati.

# Predizione selettiva e astensione



- **Esempi di regole di astensione:** due soglie anziché una, con una zona grigia in mezzo; soglia sull'incertezza stimata.
- **I due parametri della scelta:** il costo di un errore rispetto al costo del lavoro umano; la capacità disponibile — un tasso di astensione che eccede il numero di operatori non è applicabile, per quanto sia giustificato.



# Protocolli di validazione

| PROTOCOLLO                 | COME SI COSTRUISCE                                   | CHE COSA STIMA                                        |
|----------------------------|------------------------------------------------------|-------------------------------------------------------|
| hold-out singolo           | una divisione casuale in due parti                   | stima con varianza alta, dipende dalla divisione      |
| k-fold cross-validation    | k divisioni, ogni parte usata una volta come test    | performance media, con stima della variabilità        |
| cross-validation ripetuta  | più ripetizioni di k-fold con semi diversi           | riduce la dipendenza dalla singola partizione         |
| bootstrap                  | resampling con ripetizione                           | validazione interna, raccomandata su campioni piccoli |
| <b>validazione esterna</b> | <b>dati di un altro centro o di un altro periodo</b> | <b>trasportabilità del modello</b>                    |



---

# Validazione esterna e temporale

## Esterna, per centro

---

- si addestra su alcune strutture e si valuta su una (o altre) nuova.
- cambia la popolazione, il protocollo, talvolta la strumentazione
- il numero di centri disponibili è quasi sempre piccolo

## Temporale

---

- si addestra sui dati fino a una data e si valuta su quelli successivi
- cambiano prassi, definizioni, popolazione afferente





---

PASSO 5

# Production e manutenzione

# Monitoraggio in assenza di etichette

- **Il problema.** In un sistema clinico l'esito reale arriva mesi dopo, oppure non arriva mai, perché il paziente segnalato viene trattato e l'esito avverso non si osserva.
- **Drift delle variabili in ingresso.** Distribuzione di ciascuna variabile, frazione di valori assenti, comparsa di codici nuovi. Si confronta con la distribuzione di addestramento.
- **Drift della distribuzione delle probabilità predette.** È il segnale precoce di un cambio di prevalenza, e non richiede etichette: se la media delle predizioni si sposta, qualcosa è cambiato a monte.
- **Tasso di astensione e frazione di casi fuori distribuzione.** Salgono prima che salgano gli errori, e sono la spia più utile fra quelle disponibili senza esiti.

**Sono indicatori del fatto che le condizioni in cui è stato validato non valgono più.**

# Regolamentazione dei dispositivi medici

- **Quando un software è dispositivo medico.** Se è destinato dal fabbricante a scopo di diagnosi, prevenzione, monitoraggio, previsione o prognosi, ricade nel regolamento europeo sui dispositivi medici. La destinazione d'uso dichiarata è il criterio.
- **La classificazione.** Il software che fornisce informazioni usate per decisioni diagnostiche o terapeutiche ricade in classi che richiedono l'intervento di un organismo notificato.
- **Il regolamento europeo sull'intelligenza artificiale** classifica ad alto rischio i sistemi che sono componenti di sicurezza di un dispositivo medico, e aggiunge obblighi su gestione del rischio, qualità dei dati, documentazione tecnica e sorveglianza umana.
- **Le conseguenze progettuali.** Tracciabilità delle versioni, giustificazione delle scelte di modellazione, e limiti alla possibilità di aggiornare il modello senza rivalutazione.

**Sono vincoli di progetto e decidono se il modello può essere aggiornato automaticamente, e talvolta quale famiglia di modelli è sostenibile.**




---

# Trattamento dei dati sanitari

- **Categoria particolare.** I dati relativi alla salute ricevono una tutela rafforzata: il trattamento è vietato salvo specifiche condizioni, e richiede una base giuridica adeguata.
- **Minimizzazione e limitazione della finalità.** Si trattano i dati necessari allo scopo dichiarato, e non si riusano per finalità diverse senza una nuova valutazione.
- **Dove avviene l'elaborazione.** Trasferire dati a un servizio esterno è un trattamento, e va valutato prima.
- **Anonimizzazione e pseudonimizzazione non sono la stessa cosa:** la pseudonimizzazione da sola non esclude il rischio reidentificazione.

La conseguenza pratica più frequente è sull'architettura: molte scelte tecniche ragionevoli diventano impraticabili se implicano che il dato esca dall'infrastruttura in cui è stato raccolto.

# Ruolo del modello nella decisione clinica



- Il modello **propone**, il clinico decide.
- Il clinico dispone di informazioni che il modello non ha: esame obiettivo, anamnesi narrativa, contesto.
- **La soglia è una scelta clinica**, perché dichiara un rapporto fra costi che riguarda i pazienti.
- La responsabilità professionale non si trasferisce al software.

# Riproducibilità e versionamento

- **Il preprocessing fa parte del modello.** Imputazione, codifiche, standardizzazione e costruzione delle variabili derivate vanno versionate insieme ai pesi e applicate identiche in produzione.
- **La calibrazione è un artefatto inseparabile.** Va versionata con il modello su cui è stata stimata, e con l'indicazione della popolazione su cui è stata calcolata.
- **I dati vanno versionati come il codice:** definizione della coorte, criteri di inclusione, data di estrazione.
- **I random seed non bastano.** Versioni delle librerie, ordine delle operazioni e parallelismo possono cambiare il risultato.

**Un modello clinico deve poter essere ricostruito a distanza di tempo, perché è la condizione perché il suo output possa essere giustificato.**