



---

Modulo 4

# Elaborazione video e computer vision real-time



---

PASSO 0

# Obiettivi e struttura della lezione

# Argomenti della lezione

- **Il problema:** differenza fra uno stream video e un insieme di immagini, e conseguenze sull'architettura del sistema.
- **I dati:** annotazione, split, decodifica, risoluzione e dimensione degli oggetti.
- **I metodi:** detection, tracking e analisi di eventi.
- **La valutazione:** metriche di detection, di tracking e di sistema, e soglia di esercizio.
- **La produzione:** latenza, hardware, quantizzazione e monitoraggio.



---

PASSO 1

# Analisi di stream video: definizione del problema

# Analisi di stream video

Dato uno stream di immagini acquisite a frequenza costante da una o più telecamere, produrre in modo continuo la classe, la posizione e il moto degli oggetti presenti nella scena, entro un limite di tempo fissato dall'applicazione.

- la frequenza dei frame è **imposta dalla sorgente** e non dal sistema di elaborazione
- il sistema **non può accumulare ritardo** senza perdere frame
- l'uscita è **continua**: ogni frame produce un risultato, o viene scartato



# Immagine singola e stream video

## Immagine singola

---

- i campioni sono indipendenti
- il tempo di elaborazione non è vincolato
- l'annotazione di N immagini produce N esempi indipendenti

## Flusso video

---

- i campioni consecutivi sono fortemente correlati
- il tempo disponibile per frame è fissato dalla frequenza di acquisizione
- una detection mancata su un frame può interrompere un track, e l'errore resta nei frame successivi
- l'annotazione di N frame consecutivi produce molto meno di N esempi indipendenti

**A 25 frame al secondo due frame consecutivi distano 40 millisecondi: il costo dell'annotazione cresce con il numero di frame, l'informazione con il numero di scene.**

# Struttura di un sistema video



- Ogni stadio riceve in ingresso l'uscita del precedente, e non ha modo di rilevare gli errori degli stadi precedenti.
- **Un track interrotto aggiunge un'identità e falsa il conteggio.**
- Gli stadi hanno costi molto diversi.

La misura del sistema è l'uscita dell'ultimo stadio. Le metriche dei primi tre localizzano la causa di un errore.



---


# Domini di applicazione

- **Sicurezza e sorveglianza:** accesso a zone interdette, presenza di persone in aree pericolose, oggetti abbandonati.
- **Controllo di processo:** conteggio di pezzi su una linea, verifica di presenza e posizione, segnalazione di inceppamenti.
- **Traffico e logistica:** conteggio e classificazione di veicoli, occupazione di aree, tempi di attraversamento.
- **Qualità e ispezione:** difetti superficiali, completezza di un assemblaggio.
- **Analisi di comportamento:** percorsi seguiti, tempi di permanenza, code.

L'uscita richiesta è quasi sempre un conteggio o un evento.



# Propagazione degli errori lungo la catena



- Una detection mancata per pochi frame incide poco sulle metriche di detection, che mediano su tutti i frame.
- Una lacuna più lunga della tolleranza del tracker termina il track, e la ripresa successiva riceve un'identità nuova.
- **Il conteggio finale sovrastima**, perché conta le identità e non gli oggetti.

Una perdita di pochi punti nella frazione di oggetti rilevati può produrre un errore di conteggio di entità molto maggiore.

# Accuratezza, latenza e costo



- Le tre grandezze dipendono dagli stessi parametri — risoluzione, dimensione del modello, precisione numerica — e sono interdipendenti.

Un confronto fra due modelli è interpretabile solo se due delle tre grandezze sono dichiarate e uguali.

# La latenza come vincolo in ingresso

- **La latenza ammessa può variare di ordini di grandezza con l'applicazione.** Fermare una linea di produzione richiede una risposta in decine di millisecondi; un conteggio di veicoli aggiornato ogni ora tollera secondi.
- Dato un limite di latenza  $L$  e una frequenza di acquisizione  $f$ , il tempo disponibile per frame è il minore fra  $L$  e  $1/f$ . Quel tempo comprende l'esecuzione del modello e di tutti gli altri stadi.
- **Il limite di tempo esclude i modelli troppo lenti**, prima di qualunque confronto sull'accuratezza.
- I modelli utilizzabili sono determinati da quattro criteri: il numero di stream, la risoluzione, la latenza ammessa e l'hardware disponibile.

**Con quei quattro criteri dichiarati la scelta del modello è quasi obbligata.**

# Elaborazione differita e real-time

## Differita

---

- il video è già registrato
- il tempo di elaborazione non è vincolato: allungarlo costa solo più ore di calcolo
- ogni frame può essere elaborato più volte, e i frame futuri sono già disponibili

## Real-time

---

- i frame arrivano a frequenza imposta, e devono essere elaborati alla stessa frequenza
- il tempo per frame è fissato, e superarlo fa perdere frame o accumulare ritardo
- sono disponibili solo i frame già arrivati
- la memoria occupata dai track attivi tende a crescere con la durata dello stream

Le due modalità ammettono modelli diversi. Un'accuratezza misurata in differita vale anche in real-time solo se il limite di tempo non obbliga ad abbassare la risoluzione o a saltare frame.




---

PASSO 2

# I dati video: campionamento, annotazione e split



# Ridondanza temporale



- **Frame vicini portano quasi la stessa informazione.** Il costo di annotarli è però proporzionale al loro numero.
- **Più tempo passa fra due frame, più i due frame sono diversi.** Oltre un certo intervallo la differenza smette di crescere: la scena è cambiata del tutto, e due frame ancora più lontani nel tempo non sono più diversi di così.
- Quell'intervallo dipende dalla scena e dal movimento degli oggetti e della telecamera. Il valore misurato su un'installazione non vale per un'altra.



---

# Conseguenze della correlazione fra frame

- **L'incertezza delle metriche è sottostimata.** L'intervallo di confidenza calcolato assumendo campioni indipendenti è troppo stretto, perché il numero di campioni effettivamente indipendenti è una frazione del totale.
- **La correlazione è anche un'informazione utilizzabile.** La presenza di un oggetto nel frame precedente è informazione sulla sua presenza in quello corrente, ed è ciò che il tracking utilizza.

# Dallo stream ai campioni

- **Frequenza di acquisizione.** L'inferenza può essere eseguita su un frame ogni  $N$ : la frequenza di inferenza è indipendente da quella di acquisizione. Nei frame saltati la posizione degli oggetti è stimata dal tracking a partire dalle detection precedenti.
- **Risoluzione.** Il detector opera a risoluzione fissa, e ogni frame è ridimensionato a quella risoluzione. La risoluzione di ingresso determina la dimensione minima degli oggetti ancora rilevabili.
- **Profondità di colore e formato.** La conversione di formato e la normalizzazione sono eseguite su ogni frame, e il loro tempo si aggiunge a quello degli altri stadi.
- **Regione di interesse.** La restrizione alla porzione utile del frame non richiede nessuna modifica del modello. Se anche l'ingresso del detector è ridotto in proporzione, il costo scende; se l'ingresso resta lo stesso, gli oggetti occupano più pixel.





# Strategie di annotazione

| STRATEGIA                   | PROCEDURA                                                                           | COSTO UMANO                                                |
|-----------------------------|-------------------------------------------------------------------------------------|------------------------------------------------------------|
| frame chiave sparsi         | annotazione di un frame ogni $N$ , interpolazione nell'intervallo                   | proporzionale a $1/N$                                      |
| propagazione con un tracker | annotazione del primo frame, propagazione con il tracker, correzione dell'operatore | proporzionale agli errori del tracker                      |
| active learning             | annotazione dei frame di massima incertezza del modello                             | proporzionale ai frame selezionati, ripartito su più cicli |
| pseudo-etichette            | proposta di un detector a vocabolario aperto, validazione dell'operatore            | validazione invece di disegno a mano                       |

Ogni strategia riduce il lavoro di annotazione; il numero di frame usati per l'addestramento resta lo stesso.

**Nel riconoscimento di azioni sono riportati risultati ottenuti annotando il 10 % dei frame.**


*Active Sparse Labeling, NeurIPS 2022.*

# Selezione dei frame da annotare

- **Copertura delle condizioni.** I frame devono essere scelti in modo da contenere illuminazioni, occupazioni della scena e configurazioni diverse. Il campionamento uniforme nel tempo non garantisce questa copertura.
- **Eventi rari.** È necessario cercare esplicitamente i frame che contengono una classe o una condizione rara: il campionamento uniforme li omette.
- **Provenienza da più sequenze.** I frame annotati devono provenire da più riprese e da più siti: cento frame da una sequenza coprono una scena sola.

Il numero di frame annotati è il parametro meno informativo di un insieme di dati video: la varietà è determinata dal numero di sequenze, di siti e di condizioni.

# Split per frame, per sequenza e per sito




- Lo **split per frame** non misura nessuna generalizzazione: frame della stessa scena compaiono sia in addestramento sia in test, e il modello ha già osservato quella scena, quell'illuminazione e quegli oggetti.
- Lo **split per sequenza** misura la generalizzazione a una ripresa nuova dello stesso sito.
- Lo **split per sito** misura la generalizzazione a un'installazione mai osservata.

**Due telecamere nello stesso ambiente condividono sfondo, illuminazione e oggetti: appartengono allo stesso sito anche quando sono installazioni distinte.**

# Data leakage nel video

- **Split casuale dei frame.** La forma più comune, e quella che produce la sovrastima maggiore: ogni frame di test ha un frame quasi identico in addestramento.
- **Split temporale della stessa sequenza.** La seconda metà di una sequenza usata come validazione condivide con la prima metà scena, illuminazione e spesso le stesse identità.
- **Statistiche di normalizzazione calcolate su tutte le sequenze.** Le statistiche portano nell'addestramento informazione sulle sequenze di test. In esercizio sono stimate su un periodo di riferimento dichiarato.
- **Selezione del modello su un test riutilizzato.** Un test interrogato molte volte durante lo sviluppo entra nella selezione del modello, e la prestazione che riporta è ottimistica.

# Risoluzione, frame al secondo e decodifica



- Il costo di inferenza cresce **con il quadrato del lato** dell'ingresso; l'accuratezza cresce, ma oltre una certa risoluzione non cresce più.
- Il punto di lavoro è determinato dall'intersezione fra la curva del tempo e il tempo disponibile per frame.
- La **decodifica** dello stream compresso precede l'inferenza, ed è un costo per frame indipendente dal modello.

La risoluzione è il parametro con l'effetto più forte su costo e accuratezza.




# Variabilità dell'installazione

- **Altezza e angolo della telecamera** determinano la dimensione apparente degli oggetti e la frequenza delle occlusioni.
- **Focale e distorsione dell'obiettivo** cambiano la geometria dell'immagine e la relazione fra pixel e dimensione reale.
- **Illuminazione**, naturale o artificiale, cambia nell'arco del giorno e dell'anno, e produce riflessi e ombre che dipendono dalla posizione della sorgente luminosa.
- **Il bitrate della compressione** determina quanto sono marcati gli artefatti, più visibili sugli oggetti piccoli e in rapido movimento.

**L'accuratezza misurata su un'installazione non prevede quella su un'altra.**


# Dimensione degli oggetti e accuratezza



- Il detector opera a risoluzione fissa, e ogni frame è ridimensionato a quella risoluzione. La riduzione si applica anche agli oggetti.
- Sugli oggetti piccoli una variazione modesta della risoluzione di ingresso produce una variazione grande dell'accuratezza.

La grandezza che determina la rilevabilità è la dimensione dell'oggetto in pixel nell'ingresso del detector.

# Inferenza a tile



- Il frame è suddiviso in **tile**, riquadri sovrapposti su cui l'inferenza è eseguita a piena risoluzione; le detection sono poi ricomposte con una soppressione globale delle sovrapposizioni.
- La sovrapposizione fra tile deve essere almeno pari alla dimensione dell'oggetto più piccolo da rilevare, perché un oggetto a cavallo di due tile sia contenuto per intero in almeno uno.
- **Il costo si moltiplica per il numero di tile.** Numero, dimensione e sovrapposizione determinano i frame al secondo sostenibili.





PASSO 3

# Object detection: architetture e scelta del modello

# Il problema della detection

Data un'immagine, produrre l'insieme degli oggetti presenti: per ciascuno il riquadro che lo racchiude, detto **bounding box**, la classe a cui appartiene e un punteggio di confidenza. Il numero di oggetti non è noto in anticipo e varia da immagine a immagine.

- la dimensione dell'uscita **dipende dall'immagine** e non è fissata dall'architettura
- localizzazione e classificazione sono tipicamente apprese in modo congiunto, e una detection è corretta solo quando lo sono entrambe
- il punteggio di confidenza **ordina** le detection; la soglia di accettazione è esterna al modello

# Criticità della detection

- **Scala.** Nella stessa immagine gli oggetti possono differire di un ordine di grandezza in dimensione, e la stessa rete deve rilevarli tutti.
- **Affollamento e occlusione.** Oggetti sovrapposti producono bounding box sovrapposti, e nemmeno un annotatore umano distingue sempre due oggetti vicini da un oggetto solo.
- **Sbilanciamento fra le classi.** In un insieme di dati reale poche classi contengono la maggior parte degli esempi, e una media su tutte le classi nasconde il risultato sulle classi rare.
- **Sbilanciamento fra foreground e sfondo.** Le posizioni candidate sono decine di migliaia per immagine, gli oggetti alcune unità: senza un correttivo la funzione di costo è dominata dallo sfondo. La *focal loss* lo evita abbassando il peso degli esempi facili.




# Famiglie architetture

| FAMIGLIA                  | COME PRODUCE LE DETECTION                                                                                     | RAPPRESENTANTI       |
|---------------------------|---------------------------------------------------------------------------------------------------------------|----------------------|
| <b>two-stage</b>          | prima i bounding box proposti, poi la classificazione di ciascuno                                             | Faster R-CNN         |
| <b>one-stage</b>          | griglia di posizioni candidate, con o senza ancorre predefinite; per ciascuna la rete predice il bounding box | SSD, RetinaNet, YOLO |
| <b>end-to-end a query</b> | un insieme fisso di query, messe in corrispondenza uno a uno con gli oggetti                                  | DETR e successori    |

La soppressione dei duplicati richiede una soglia da tarare; le architetture a query non ne hanno bisogno.


# Architettura di un detector one-stage



- Il **backbone** estrae le caratteristiche, il **neck** le combina fra scale diverse, la **testa** produce le predizioni su ciascuna scala.
- Le **ancore** sono bounding box di posizione e proporzioni predefinite: la rete predice lo scarto fra l'ancora e l'oggetto invece delle coordinate assolute. Le versioni senza ancore predicono il bounding box direttamente dalla cella.
- L'assegnamento stabilisce quale ancora è responsabile di quale oggetto, di norma per sovrapposizione. Più ancore superano la soglia sullo stesso oggetto, che risulta quindi predetto più volte.



# NMS




- La **non-maximum suppression** ordina le detection per punteggio, conserva la prima ed elimina quelle che si sovrappongono a essa oltre una soglia; poi ripete sul resto.
- La soglia non è appresa: cambiarla non richiede riaddestramento.
- Il passo è eseguito dopo la rete, sui bounding box prodotti, e separatamente per ogni classe.

# Limiti della NMS

- **Due oggetti distinti che si sovrappongono sono fusi in uno.** La regola non distingue un duplicato da due oggetti vicini, e in una scena affollata la sovrapposizione fra oggetti distinti supera regolarmente la soglia.
- **La soglia è un parametro aggiuntivo**, tarato su un insieme di dati di riferimento con densità e occlusioni diverse da quelle dell'installazione in cui il sistema opera.
- **La latenza dipende dai dati.** Il costo cresce con il numero di detection, quindi il tempo per frame varia con l'affollamento della scena.
- **Il caso peggiore conta quanto la media.** In un sistema real-time i frame persi dipendono dal tempo massimo per frame, e da quel tempo parte il dimensionamento dell'hardware.

# Matching uno a uno




- Nelle architetture a query un insieme fisso di query produce le predizioni. Durante l'addestramento ogni oggetto vero è associato a una sola query, con il matching di costo minimo.
- Il matching uno a uno rende **l'uscita priva di duplicati**: nessun passo di soppressione, e una latenza che non dipende dal contenuto della scena.
- Le query non associate sono addestrate a predire l'assenza di oggetto.

**I detector real-time più recenti non usano la soppressione dei duplicati: le architetture a query non ne hanno mai avuto bisogno, e i detector a griglia hanno adottato in addestramento lo stesso matching uno a uno.**



# Accuratezza in funzione della latenza



- Il confronto fra modelli è su due grandezze: un modello ne domina un altro solo se è migliore su entrambe.
- **La scelta è il modello più accurato fra quelli che rispettano il limite di tempo.** I modelli più lenti non entrano nel confronto, per quanto siano accurati.
- La latenza dichiarata è misurata sul solo modello, con hardware e precisione numerica specificati. La latenza dell'intera catena, sull'hardware di esercizio, può risultare maggiore.

**Cambiando il limite di tempo cambia il modello scelto, a parità di altre condizioni.**




# Modelli di riferimento

| MODELLO        | ELEMENTO DISTINTIVO                                                                                  |
|----------------|------------------------------------------------------------------------------------------------------|
| RF-DETR        | primo modello real-time oltre 60 di precisione media su COCO                                         |
| YOLO26         | end-to-end, senza NMS; 57,5 di precisione media con meno parametri della variante DETR confrontabile |
| RT-DETR v2, v3 | ha portato l'architettura a query nel real-time                                                      |
| RTMDet         | oltre 300 frame al secondo nella variante più piccola                                                |

Le precisioni medie citate qui sopra, 60 e 57,5, sono misurate su COCO dagli autori dei rispettivi modelli, e non sono confrontabili con misure fatte su un insieme di dati diverso.

# Detection a vocabolario aperto



esempi di descrizione

«carrello elevatore»

«persona senza casco»

«porta antincendio aperta»

- Le classi sono descritte a parole al momento dell'inferenza, invece di essere fissate durante l'addestramento.
- Immagine e descrizione sono proiettate in uno spazio comune, e il punteggio di una detection è la somiglianza fra la rappresentazione del bounding box e quella della descrizione.
- **L'inferenza costa più** che con un detector chiuso di pari precisione, e la latenza esclude questi modelli dalla maggior parte dei sistemi real-time.
- **L'impiego principale è la produzione di pseudo-etichette:** il modello propone le annotazioni su un archivio non etichettato, un operatore valida, e il risultato addestra un detector chiuso e veloce.

Nella maggior parte dei sistemi il modello a vocabolario aperto serve a produrre i dati, non a fare inferenza in esercizio.

Grounding DINO, YOLO-World.

# Adattamento a un dominio ristretto

- **Un dominio ristretto ha poche classi e molta ripetizione.** Un detector generico addestrato sulle ottanta classi di COCO spende parte della sua capacità su classi che in quel dominio non compaiono.
- **L'adattamento parte da pesi pre-addestrati** e prosegue sull'insieme di dati dell'installazione. Il numero di immagini richiesto è dell'ordine delle centinaia per classe, non delle decine di migliaia.
- **Il dominio determina quali trasformazioni di aumento dei dati sono ammissibili.** Il ribaltamento orizzontale è ammesso su una scena simmetrica, non dove l'orientamento porta informazione; le variazioni di luminosità e contrasto riproducono condizioni che nell'installazione si presentano davvero.
- **Le trasformazioni che compongono più immagini**, mosaic e mixup, aumentano la varietà delle scene e producono configurazioni che nell'installazione non si verificano mai.

Le trasformazioni che generano condizioni impossibili nell'installazione addestrano il modello su scene che non si presenteranno.

# Uscite alternative al bounding box

- **Segmentazione di istanza:** una maschera per oggetto invece di un bounding box. Serve quando la forma è la grandezza di interesse, come nella misura di area e nell'ispezione di superfici.
- **Segmentazione semantica e panottica:** una classe per pixel. La semantica descrive regioni estese e non distingue le istanze; la panottica unisce regioni e istanze in un'unica uscita.
- **Stima della posa:** un insieme di punti articolari, o keypoint, per oggetto. Serve quando l'evento dipende da come sono disposte le parti di un corpo o di un meccanismo.
- **Segmentazione su video a partire da un'indicazione**, o *promptable segmentation*: la maschera si propaga dal frame in cui l'indicazione è data ai successivi.

Queste uscite costano più per frame della detection a bounding box, e sono giustificate quando il bounding box non contiene la grandezza da misurare.





---

PASSO 3.5


# Tracking e analisi di eventi

# Tracking multi-oggetto

Dato per ogni frame l'insieme delle detection, assegnare a ciascuna un'identità persistente, in modo che le detection dello stesso oggetto in frame diversi ricevano la stessa identità e oggetti diversi ricevano identità distinte.

- l'uscita è **una traiettoria per oggetto**, con un istante di nascita e uno di morte
- il problema è di **associazione**: stabilire quale detection appartiene a quale track
- le detection in ingresso fissano il massimo numero di track

# Lo schema tracking-by-detection




- **Lo schema è comune a tutti i tracker tracking-by-detection.** Le differenze fra un tracker e l'altro stanno nella matrice che dà il costo di ogni coppia track-detection, e nella regola che sceglie quali coppie tenere.
- Il modello di moto predice dove il track si troverà; il costo misura quanto ogni detection si accorda con ogni predizione.

L'associazione è risolta da un'ottimizzazione combinatoria sulla matrice di costo.



# Filtro di Kalman, predizione e correzione

blocco di predizione



Per ogni track il filtro tiene una stima e la sua incertezza, e le aggiorna a ogni frame con due passi.

**Predizione** — sempre

$$\mathbf{x} \leftarrow \mathbf{x} + \mathbf{v} \cdot \Delta t$$

$$\mathbf{P} \leftarrow \mathbf{P} + \mathbf{Q}$$

**Correzione** — solo se arriva una detection  $z$

$$\mathbf{K} = \mathbf{P} / (\mathbf{P} + \mathbf{R})$$

$$\mathbf{x} \leftarrow \mathbf{x} + \mathbf{K} \cdot (\mathbf{z} - \mathbf{x})$$

$$\mathbf{P} \leftarrow (\mathbf{I} - \mathbf{K}) \cdot \mathbf{P}$$

$\mathbf{x}$  — posizione stimata

$\mathbf{v}$  — velocità stimata

$\Delta t$  — intervallo fra due frame

$\mathbf{P}$  — incertezza della stima

$\mathbf{Q}$  — errore del modello di moto

$\mathbf{z}$  — posizione della detection

$\mathbf{R}$  — errore della detection

$\mathbf{K}$  — peso dato alla detection

Le formule sono ridotte a una grandezza sola; nel filtro completo la correzione aggiorna anche la velocità e  $\mathbf{P}$  è una matrice.

# Filtro di Kalman, predizione e correzione

blocco di predizione

- **K sta fra 0 e 1 e dice a quale delle due fonti credere.** Detection precise, cioè  $R$  piccolo, portano  $K$  verso 1 e la stima segue la detection; detection rumorose portano  $K$  verso 0 e la stima segue la predizione.
- **Senza detection resta la sola predizione:**  $P$  cresce a ogni frame e non si riduce. È il meccanismo che porta il track attraverso un'occlusione breve.

La predizione del filtro è la posizione attesa con cui il costo confronta ogni detection.

---

Le formule sono ridotte a una grandezza sola; nel filtro completo la correzione aggiorna anche la velocità e  $P$  è una matrice.

# Matrice di costo e assegnamento

blocchi di costo e assegnamento

|       |    | detection |      |      |      |
|-------|----|-----------|------|------|------|
|       |    | D1        | D2   | D3   | D4   |
| track | T1 | 0,11      | 0,24 | 0,86 | 0,94 |
|       | T2 | 0,08      | 0,62 | 0,78 | 0,91 |
|       | T3 | 0,88      | 0,71 | 0,16 | 0,83 |
|       | T4 | 0,93      | 0,89 | 0,82 | 0,90 |

le celle il cui costo supera la soglia, qui 0,70, non sono ammissibili

track non associato

detection non associata

- L'assegnamento seleziona l'insieme di coppie di costo totale minimo, con un track associato al più a una detection e viceversa.
- Le coppie il cui costo supera una soglia sono escluse: un track resta senza detection e una detection senza track. Il track accumula frame senza associazione, la detection può dare origine a un track nuovo.

Tre parametri determinano il comportamento del tracker: la soglia di ammissibilità del costo, i frame senza detection tollerati prima della chiusura di un track, e i frame necessari a confermarne uno nuovo.


# Failure mode del tracking

- **Occlusione prolungata.** Il track supera il numero di frame di sopravvivenza, viene chiuso, e la ricomparsa dell'oggetto genera un'identità nuova.
- **Moto non conforme al modello.** Un'accelerazione, un cambio di direzione brusco o un arresto producono una predizione lontana dalla detection, che quindi non viene associata.
- **Movimento della telecamera.** Lo spostamento apparente di tutti gli oggetti fra due frame consecutivi invalida il modello di moto contemporaneamente per tutti i track.
- **Oggetti simili e vicini.** Con un costo puramente geometrico, due oggetti che si incrociano ammettono due assegnamenti di costo quasi uguale, e la scelta fra i due non è determinata dai dati.

Occlusione prolungata, moto non conforme e movimento della telecamera interrompono i track e gonfiano il conteggio degli oggetti distinti. Gli oggetti simili e vicini producono identità scambiate, che lasciano il conteggio invariato.

# Associazione a due passate

blocco di assegnamento



- Un oggetto parzialmente occluso produce una detection a confidenza bassa, che una soglia unica sul punteggio scarta. Il punteggio basso riflette l'occlusione e non un errore di localizzazione: la posizione resta corretta.
- Le detection deboli sono associate in una seconda passata ai soli track rimasti senza associazione, sulla sovrapposizione geometrica.
- Il costo aggiuntivo è quello di una seconda matrice di costo, di dimensione molto minore della prima.

**Meno track interrotti e meno identità scambiate, senza nessuna rete aggiuntiva: cambia la sola regola di associazione, e il detector non richiede riaddestramento.**





---

# Re-identificazione, il termine di aspetto

blocco di costo

- **Il costo geometrico non distingue oggetti che occupano la stessa regione.** Quando due traiettorie si incrociano, la sovrapposizione è compatibile con entrambi gli assegnamenti.
- Una rete di re-identificazione produce una rappresentazione vettoriale per ogni bounding box, e il costo diventa una combinazione della distanza geometrica e della distanza fra rappresentazioni.
- **La rete di re-identificazione è eseguita per ogni bounding box e per ogni frame.** Il tempo che richiede cresce con l'affollamento della scena, e si somma a quello del detector.
- La rappresentazione di aspetto consente anche di riassociare un oggetto uscito dall'inquadratura e rientrato, che il solo modello di moto non ritrova.

Con la re-identificazione il costo del tracking smette di essere trascurabile accanto a quello della detection, e la scelta richiede la latenza misurata insieme al guadagno.

# Compensazione del moto della telecamera

blocco di predizione

- **Il modello di moto dei track è espresso nel sistema di riferimento dell'immagine.** Se la telecamera si sposta, tutti gli oggetti si spostano nell'immagine, e tutte le predizioni risultano errate per effetto della stessa trasformazione.
- La compensazione stima la trasformazione geometrica fra due frame consecutivi a partire dallo sfondo, e la applica alle predizioni prima di calcolare i costi.
- Serve su riprese a mano, da veicolo, da drone e su telecamere orientabili. **Su una telecamera fissa non produce effetto**, e non c'è ragione di eseguirla.
- La stima è un'operazione di visione classica sul frame, e il suo costo non dipende dal numero di oggetti.



# Tracker notevoli

| TRACKER              | CHE COSA AGGIUNGE                                    | COSTO AGGIUNTIVO                    | QUANDO SERVE                     |
|----------------------|------------------------------------------------------|-------------------------------------|----------------------------------|
| <b>SORT</b>          | modello di moto e assegnamento sulla sovrapposizione | nullo                               | riferimento di partenza          |
| <b>ByteTrack</b>     | seconda passata sulle detection deboli               | trascurabile                        | occlusioni parziali frequenti    |
| <b>BoT-SORT</b>      | compensazione del moto della telecamera              | basso, indipendente dagli oggetti   | telecamera mobile                |
| <b>BoT-SORT-ReID</b> | rappresentazione di aspetto                          | una rete per bounding box per frame | oggetti simili che si incrociano |

**SORT e ByteTrack non aggiungono nessuna rete e coprono la maggior parte dei casi. La re-identificazione è l'unica aggiunta che cambia l'ordine di grandezza del costo.**






---

# Tracker end-to-end

- Una rete unica riceve la sequenza e produce direttamente le traiettorie, apprendendo l'associazione invece di codificarla in una regola.
- **I tracker end-to-end non hanno sostituito quelli euristici nei sistemi in esercizio.**

Il vantaggio che un metodo euristico mostra sui benchmark pubblici non si trasferisce a un'installazione che ha dati propri.

# Telecamera fissa, sottrazione dello sfondo



- Su una telecamera fissa il valore di ogni pixel nel tempo ammette un modello statistico, e ciò che se ne discosta è foreground. Il costo di calcolo è basso.
- **Trova oggetti in movimento più piccoli di quelli che un detector riesce a rilevare** alla risoluzione di ingresso, e in cambio produce molte detection spurie.
- **L'uscita è priva di semantica:** indica dove c'è movimento, non che cosa si sia mosso.
- **Come filtro davanti al detector,** riduce il numero di passaggi di inferenza in proporzione alla frazione di scena in movimento.

**Su una scena vuota per nove decimi del tempo, i passaggi di inferenza scendono a un decimo.**



---

# Dall'oggetto all'evento

- **Linee di conteggio:** un oggetto attraversa un segmento in un verso dichiarato. L'evento è l'attraversamento, e richiede la traiettoria prima e dopo la linea.
- **Zone:** un oggetto entra in una regione, vi permane oltre una durata dichiarata, ne esce.
- **Relazioni fra track:** due oggetti si avvicinano oltre una soglia, o si muovono insieme.
- **Assenza:** una regione che deve contenere un oggetto non lo contiene per una durata dichiarata.

# Riconoscimento di azioni

- Quando l'evento è definito dal movimento e non dalla posizione, la regola sui track non lo esprime: l'ingresso diventa **una finestra di frame**.
- **Classificazione di azione**: data una clip, l'azione che vi è contenuta.
- **Localizzazione temporale**: dato uno stream continuo, l'istante di inizio e di fine dell'azione. È quella che un sistema di monitoraggio richiede, ed è la più difficile.
- **Altri problemi dello stesso ambito**: la localizzazione spazio-temporale, la segmentazione temporale, la detection online e l'anticipazione. Ognuno ha un'uscita diversa.
- **La finestra introduce latenza**. Data una finestra di  $L$  frame a frequenza  $f$ , la risposta non può precedere  $L/f$  secondi dall'inizio dell'azione.



---

PASSO 4

# Metriche di detection, di tracking e di sistema




# Intersection over Union (IoU)

Dati un bounding box predetto e un bounding box vero, l'**Intersection over Union**, o **IoU**, è il rapporto fra l'area della loro intersezione e l'area della loro unione. Vale 1 quando coincidono e 0 quando sono disgiunti.

- riassume in un numero solo l'errore di posizione e quello di dimensione
- una predizione è contata come corretta quando il valore supera una **soglia predefinita**, che non ha una giustificazione teorica: l'ordinamento fra due detector può cambiare con la soglia scelta
- il valore non cambia ingrandendo insieme predizione e riferimento, ma **uno scarto di pochi pixel pesa molto di più su un oggetto piccolo**

# Curva precision-recall e average precision



- Le detection sono ordinate per punteggio decrescente. Percorrendo l'elenco, ogni detection corretta aumenta il **recall**, ogni errata abbassa la **precision**.
- L'**average precision** è l'area sotto questa curva, e riassume il comportamento del detector su tutte le soglie di confidenza.
- Il **mAP** è la media dell'average precision sulle classi.
- **mAP50** è calcolato alla sola soglia di IoU 0,50. **mAP50-95** media anche su dieci soglie da 0,50 a 0,95, a passi di 0,05, ed è il valore che i benchmark riportano come principale.

Il sistema in esercizio opera in un solo punto della curva, fissato dalla soglia di confidenza.



---

# Limiti del mAP

## PROPRIETÀ DELLA METRICA

## CONSEGUENZA

la soglia di IoU è arbitraria

due sistemi con lo stesso valore possono localizzare in modo molto diverso

valuta la sola posizione predetta e ignora l'incertezza che il modello dichiara su di essa


il valore non dice quanto sia affidabile una singola detection

è un valore unico, mediato su tutte le taglie e su tutte le classi

un detector può essere inutilizzabile sugli oggetti piccoli, o sulla classe rara che interessa, e avere un buon valore




# mAP per taglia e per classe



- **Due detector con lo stesso valore complessivo possono avere comportamenti opposti sulle taglie.** La scelta fra i due dipende dalla taglia degli oggetti dell'installazione.
- La media sulle classi attribuisce lo stesso peso a una classe con migliaia di esempi e a una con decine, mentre sulla classe rara l'incertezza è molto maggiore.
- La disaggregazione per taglia e per classe non richiede nessuna misura aggiuntiva: sono le stesse detection, raggruppate diversamente.

Su una classe con poche decine di esempi il valore è troppo incerto per decidere, e prima di confrontare serve annotarne altri.

# Prestazioni in funzione della soglia di confidenza



- Il mAP integra su tutte le soglie di confidenza, e non determina quale soglia usare in esercizio.
- **La distribuzione dei punteggi dipende dal detector.** Una stessa soglia numerica seleziona frazioni di detection diverse da un modello all'altro, e il suo valore non è confrontabile.
- **La soglia sceglie il punto di lavoro:** ogni valore corrisponde a un rapporto diverso fra oggetti non rilevati e detection spurie.

# Scelta della soglia di esercizio


- **La soglia è determinata dal rapporto fra i costi dei due errori**, che è una grandezza dell'applicazione: quanto costa un oggetto non rilevato e quanto costa una detection spuria.
- **I due errori non hanno le stesse conseguenze a valle.** Un oggetto non rilevato interrompe un track; una detection spuria ne crea uno nuovo, e i due errori si propagano in modo diverso sul conteggio.
- **La taratura della soglia richiede dati dell'installazione**, e non l'insieme di dati con cui il modello è stato confrontato.
- **Cambiare modello richiede di ritarare la soglia**, perché la distribuzione dei punteggi cambia anche a parità di precisione media.

# Calibrazione di un detector

- **Il punteggio prodotto da un detector non è una probabilità.** Un valore di 0,9 non corrisponde a nove detection corrette su dieci con quel punteggio.
- **Lo scarto di calibrazione** è, in ogni intervallo di punteggio, la differenza fra il punteggio medio e la frazione di detection corrette.
- **Lo stesso oggetto riceve punteggi diversi al variare di dimensione, occlusione e illuminazione.**
- Esistono metodi che accompagnano la singola detection con una garanzia statistica di copertura, al prezzo di un insieme di calibrazione dedicato.

Un punteggio non calibrato ordina correttamente le detection, ma non può essere moltiplicato o sommato ad altre probabilità.

# Metriche di tracking



$$\text{DetA} = \text{TP} / (\text{TP} + \text{FN} + \text{FP})$$

AssA = media, su tutte le detection abbinate, di  $\text{TPA} / (\text{TPA} + \text{FNA} + \text{FPA})$

$$\text{HOTA}(\alpha) = \sqrt{(\text{DetA} \cdot \text{AssA})}$$

alla soglia di IoU  $\alpha$

HOTA = media di  $\text{HOTA}(\alpha)$  su 19 soglie  $\alpha$  da 0,05 a 0,95

**TP** — detection abbinate a un oggetto vero

**FN** — oggetti veri rimasti senza detection

**FP** — detection senza oggetto vero

**TPA, FNA, FPA** — le stesse tre quantità contate lungo la coppia di track a cui la detection abbinata appartiene

**$\alpha$**  — soglia di IoU sopra la quale una detection può essere abbinata



# Metriche di tracking

- **DetA** misura quanti oggetti sono trovati, indipendentemente dall'identità. **AssA** misura quanto le identità sono mantenute nel tempo, indipendentemente da quanti oggetti siano stati trovati.
- **La localizzazione non entra nel prodotto**, ed è riportata a parte come *LocA*, la IoU media delle detection abbinate. Entra invece nella media su  $\alpha$ : un tracker che localizza male perde le detection abbinate alle soglie alte.
- **La media è geometrica**. Un valore basso su una delle due non si compensa con un valore alto sull'altra, e un valore nullo azzerava HOTA.
- Le componenti indicano dove intervenire: su **DetA** agisce il detector, su **AssA** la regola di costo, su **LocA** la risoluzione di ingresso e la qualità dell'annotazione.




---

# Prestazione della pipeline completa

- **Accuratezza sull'uscita che l'applicazione produce.** Se l'uscita è un conteggio, la grandezza da misurare è l'errore di conteggio; il mAP e le metriche di tracking sono misure intermedie di stadi interni.
- **Latenza end-to-end**, che comprende ingestione, decodifica, preprocessing, inferenza e post-processing. Il tempo del solo modello è una frazione del totale, e gli stadi restanti sono comuni a tutti i modelli confrontati.
- **Il tempo deve essere misurato stadio per stadio**, perché il guadagno ottenibile ottimizzando uno stadio non può superare la frazione di tempo che quello stadio occupa.
- **Consumo elettrico e memoria occupata** alle condizioni di esercizio, cioè con il numero di stream previsto.
- Accuratezza, latenza e consumo descrivono un sistema solo se misurati insieme sulla stessa configurazione.

# Latenza media e latenza al 99° percentile



- La distribuzione dei tempi per frame è asimmetrica: la coda destra è prodotta dagli stadi il cui costo dipende dal contenuto della scena.
- **I frame persi sono determinati dalla coda, non dalla media.** Un sistema con media ampiamente entro il limite può perdere una frazione non trascurabile di frame.
- Il valore da dichiarare è il percentile alto, misurato sulla pipeline completa e su una registrazione che comprenda le condizioni di massimo affollamento.






---

PASSO 5

# Produzione, latenza e deployment

# Gli stadi di una pipeline video



- La sequenza degli stadi è indipendente dalla tecnologia impiegata.
- L'inferenza è **uno stadio fra gli altri**, e di norma non è quello dominante.
- Ogni stadio occupa memoria propria, e al crescere del numero di stream ciascuno cresce in modo diverso.

La latenza end-to-end è la somma dei tempi di tutti gli stadi; il numero di stream sostenibili dipende invece dai requisiti di calcolo e dalla memoria che gli stadi occupano insieme.

# Progettazione a partire dal vincolo



- Il modello è l'ultima scelta della catena.
- Numero di stream, risoluzione, frequenza, latenza ammessa e hardware sono grandezze che dipendono dall'applicazione e dall'impianto.
- Tutti gli altri vincoli determinano l'**insieme dei modelli utilizzabili**, e la loro accuratezza determina la scelta.

**L'insieme dei modelli così ottenuto può essere vuoto. In tal caso, devono essere rilassati i vincoli e le grandezze a monte: risoluzione, frequenza, numero di stream, hardware.**



# Precisione numerica e calibrazione

| PRECISIONE NUMERICA      | GUADAGNO IN VELOCITÀ | COSTO IN ACCURATEZZA                | REQUISITO                  |
|--------------------------|----------------------|-------------------------------------|----------------------------|
| 32 bit in virgola mobile | riferimento          | nessuno                             | nessuno                    |
| 16 bit in virgola mobile | circa un fattore due | trascurabile                        | supporto dell'hardware     |
| 8 bit interi             | fra 1,5 e 3,3 volte  | fra 3 e 7 punti di precisione media | un insieme di calibrazione |

**I modelli piccoli sono i più danneggiati** dalla riduzione a interi, perché hanno meno parametri in eccesso su cui assorbire l'errore di arrotondamento.

Valori da *Quantization Robustness*, arXiv:2508.19600.



---

# Elaborazione sul posto e su server

## Sul posto

---

- latenza bassa e prevedibile, indipendente dalla rete
- sulla rete transitano i soli metadati
- il video non lascia il sito
- ogni sito richiede il proprio hardware
- l'aggiornamento riguarda ogni dispositivo installato

## Su server


---

- la latenza comprende il tempo di rete e la sua variabilità
- sulla rete transita il video, con la banda che ogni stream richiede
- il video lascia il sito, con i vincoli di trattamento dei dati personali che ne derivano
- l'hardware è condiviso fra gli stream di tutti i siti
- l'aggiornamento è eseguito in un punto solo

Le architetture in esercizio sono spesso miste: elaborazione elementare vicino alla telecamera per la reattività e per ridurre la banda, modelli più complessi centralizzati e su porzioni selezionate dello stream.



# Throughput e latenza in funzione della dimensione del batch



- Il batching agisce in direzioni opposte sulle due grandezze: aumenta il throughput e peggiora la latenza del singolo frame, perché il primo frame del batch attende l'ultimo.
- Oltre una certa dimensione il vincolo diventa la memoria disponibile, e il guadagno di throughput si arresta e può invertirsi.
- La regola operativa è batch unitario per il real-time, batch grande per l'elaborazione differita.

Il throughput dichiarato da un benchmark è misurato al batch che lo massimizza, che non è quello dell'esercizio real-time.



---

# Drift in un sistema di visione

- **La telecamera si sposta o viene sostituita.** L'inquadratura cambia, e con essa la dimensione apparente degli oggetti e la geometria delle eventuali zone dichiarate.
- **L'obiettivo si sporca o si appanna.** Il contrasto diminuisce in modo graduale, e con esso il punteggio di confidenza delle detection.
- **L'illuminazione cambia** con l'ora, con la stagione e con la manutenzione degli impianti.
- **La scena cambia:** un macchinario spostato, una superficie ridipinta, un flusso di lavoro riorganizzato.

**Nessuna di queste cause produce un errore di esecuzione. Il sistema continua a elaborare frame e a emettere alert, e il calo di prestazione è evidente solo monitorando il sistema in produzione.**



---

# Monitoraggio senza etichette

- **Numero di detection per frame e distribuzione dei punteggi**, confrontati con il periodo di riferimento. Un calo di prestazione si manifesta qui prima che nell'uscita applicativa.
- **Lunghezza media dei track**. Si accorcia quando le detection diventano intermittenti, ed è già prodotta dal tracker.
- **Distanza fra la distribuzione delle rappresentazioni dei frame** e quella del periodo di addestramento, con una soglia dichiarata.
- **Raccolta del feedback**. L'esito di ogni alert, confermato o rifiutato da un operatore, è un'etichetta, e i frame corrispondenti costituiscono l'insieme di dati di riaddestramento.