



Modulo 5

AI generativa multimodale: voice cloning, lip sync e traduzione video



PASSO 0

Obiettivi e struttura della lezione



Argomenti della lezione

- **Il problema:** sintesi, conversione della voce e ridoppiaggio di un video, e le caratteristiche del problema.
- **I dati:** rappresentazione della voce e preparazione del video.
- **I metodi:** architetture di sintesi e voice cloning, lip sync e traduzione video.
- **La valutazione:** metriche automatiche e giudizio percettivo.
- **La produzione:** latenza, marcatura dei contenuti sintetici e obblighi dell'AI Act.



Avvertenze

- La lezione presenta i **principi** e le cose da sapere per orientarsi nel campo. I metodi sono mostrati nel loro funzionamento generale, senza entrare nei dettagli di addestramento e implementazione.
- Le indicazioni su AI Act e GDPR sono da considerarsi orientative.



PASSO 1

Generazione di voce e video: definizione del problema

Generazione di un segnale percepito come autentico

Dato un testo, un parlato o un video di una persona che parla, produrre un segnale — voce, video o entrambi — che un essere umano percepisca come autentico.

- l'ingresso può essere **testo, parlato o video**, e i tre casi sono compiti distinti
- l'uscita è un **segnale continuo**, voce o immagine, al posto di una classe o di un valore
- il criterio di accettazione è **percettivo**

Caratteristiche del problema

- **L'etichetta non esiste.** La stessa frase ammette molte letture tutte accettabili, e non c'è un'uscita corretta da cui misurare la distanza.
- La metrica di riferimento è il **giudizio umano**. Ogni misurazione automatica è da considerarsi un proxy.
- La voce e il volto che il modello riproduce possono appartenere a una persona reale, che ha diritti su di essi.

Dal 2 agosto 2026 chi genera contenuti sintetici ha obblighi di marcatura e di dichiarazione.

Sintesi, conversione, ridoppiaggio

sintesi da testo



conversione della voce



ridoppiaggio



- **L'identità vocale prodotta può essere di un parlante fissato oppure clonata** da un campione di riferimento, e la scelta cambia il regime di consenso.

Intelligibilità, somiglianza, naturalezza

Le parole si capiscono. La voce assomiglia a quella di riferimento. Il risultato non si distingue da una registrazione.


- sono **tre proprietà indipendenti**
- intelligibilità e somiglianza sono misurabili automaticamente in modo efficace
- per la naturalezza **nessuna metrica automatica è affidabile**



PASSO 2

I dati: rappresentazione della voce e preparazione del video

Forma d'onda, spettrogramma, token




- La forma d'onda contiene tutto il segnale ed è la rappresentazione più costosa da modellare direttamente.
- Lo spettrogramma mel è l'**energia in bande di frequenza su finestre brevi e successive**, con le bande più fitte dove l'orecchio distingue meglio. Accorcia la sequenza di due ordini di grandezza, resta continuo, ma perde la fase: per tornare al suono serve un modello addestrato.
- **I token sostituiscono i valori continui con simboli**, al prezzo della perdita introdotta dalla codifica.



La rappresentazione discreta e la modellazione di sequenze

- Una sequenza di simboli da un vocabolario finito è **la stessa forma di dato del testo**.
- La sintesi vocale diventa quindi **predizione del simbolo successivo**, e riusa architetture, tecniche di addestramento e forme di condizionamento sviluppate per il testo.
- La conversione fra suono e simboli resta un modello a sé, addestrato una volta e condiviso da tutti i sistemi che generano token.

Quantizzazione vettoriale residua



- Un autoencoder comprime il segnale in vettori latenti; la quantizzazione sostituisce ogni vettore con **la voce più vicina di un dizionario finito**, detto **codebook**, e il simbolo è il suo indice.
- Un solo codebook perderebbe troppa informazione. Lo stack codifica a ogni livello il **residuo**, cioè la differenza fra il vettore e la sua approssimazione al livello precedente.

- Ogni istante di audio è rappresentato da tanti simboli quanti sono i livelli.
Gli ultimi livelli possono essere scartati senza perdere il contenuto.

Il dato video per il lip sync



- Il modello di lip sync riceve **solo la regione della bocca**, già ritagliata e allineata.
- L'allineamento porta la bocca sempre nella stessa posizione, così il modello non deve anche localizzarla.

Failure mode della preparazione del dato video

- **Volto parzialmente coperto:** una mano, un microfono o un oggetto davanti alla bocca producono una regione ritagliata che non contiene la bocca.
- **Volto di profilo:** la bocca è visibile in scorcio o non è visibile, e l'allineamento restituisce una regione non confrontabile con quelle frontali.
- **Più volti nell'inquadratura:** la preparazione deve stabilire quale volto sta parlando.
- **Cambio di inquadratura:** il volto salta di posizione fra due frame consecutivi, e il modello li tratta comunque come una sequenza continua.

Addestrare, adattare, clonare: materiale necessario

SCOPO	MATERIALE	ADDESTRAMENTO	REQUISITI
addestrare da zero	migliaia di ore, molti parlanti	completo	infrastruttura dedicata
adattare a una voce	da pochi minuti a poche ore della stessa voce	fine-tuning	dati e GPU
clonare in zero-shot	pochi secondi	nessuno	modello zero-shot

Con il voice cloning in zero-shot, pochi secondi di una registrazione pubblica bastano a produrre una voce ragionevolmente naturale e simile all'originale.



PASSO 3

La voce: sintesi, voice cloning e conversione

Baseline: sintesi concatenativa e parametrica

Concatenativa


- frammenti di parlato registrato, selezionati e concatenati
- intelligibile, e con giunzioni udibili fra un frammento e l'altro
- la voce è quella del parlante registrato: una voce nuova richiede una nuova campagna di registrazione

Parametrica

- un modello statistico predice i parametri da cui il segnale è sintetizzato
- fluida, priva di giunzioni, e con un timbro sordo riconoscibile
- la voce è controllabile per parametri, entro un margine stretto

Il criterio di qualità è passato dall'intelligibilità alla naturalezza, e le metriche costruite per la prima non misurano la seconda.

Architettura a due stadi: modello acustico e vocoder



- La separazione permette di addestrare i due stadi su materiale diverso: il vocoder richiede solo audio, senza trascrizione.
- Ciascuno stadio è sostituibile senza riaddestrare l'altro, e lo stesso vocoder serve modelli acustici diversi.
- È l'architettura ancora scelta quando la velocità conta più della qualità.

Voice cloning zero-shot

Dato un testo e pochi secondi di registrazione di un parlante, produrre il parlato di quel testo con la voce di quel parlante, senza addestramento aggiuntivo.

- **zero-shot**: il parlante di riferimento non compare nel materiale su cui il modello è stato addestrato
- dal campione il modello prende l'identità vocale, e il testo da leggere è indipendente da quello che il campione dice
- la qualità dipende dalla **pulizia del campione** più che dalla sua durata

Il modello di linguaggio sui token audio



- Il campione di riferimento è dato in ingresso insieme al testo, e il modello continua la sequenza con la voce del campione, e anche con il suo rumore di fondo.
- **Nessun peso viene modificato:** l'adattamento alla voce sta tutto nel contesto.

- La capacità di imitare una voce nuova **viene dall'addestramento su molti parlanti.**

Anche le risorse di calcolo richieste sono modeste: il modello è scaricabile già addestrato e gira su un computer ordinario.



Controllo della sintesi: prosodia, emozione e lingua

- I sistemi di sintesi con voice cloning accettano indicazioni sulla **prosodia** — velocità, enfasi, pause, intonazione — sul registro emotivo e sull'accento, e possono leggere in una lingua diversa da quella del campione di riferimento.
- Il controllo è **indiretto**: passa per un campione di riferimento, per etichette grossolane o per una descrizione a parole.

Conversione della voce e disentanglement



- La separazione fra **contenuto** e **identità** del parlante, detta **disentanglement**, è il meccanismo su cui sono costruiti i sistemi di conversione.
- «Stesso suono» vuol dire la stessa vocale o la stessa consonante. Il metodo confronta i frammenti su una rappresentazione che dipende da quale suono si pronuncia e poco da chi lo pronuncia, e sceglie il frammento dell'altro parlante più vicino.
- Un metodo semplice, **kNN-VC**, sostituisce ogni frammento del parlato di partenza con lo **stesso suono** preso da una registrazione dell'altro parlante, e un vocoder riporta il risultato in audio.
- La separazione è **imperfetta**: parte dell'identità resta nella rappresentazione del contenuto.
- La conversione cambia solo la voce di una registrazione esistente: parole, pause ed enfasi restano quelle originali. Per far dire parole diverse serve la sintesi.



PASSO 3.5

Il video: lip sync e traduzione

Lip sync

Dato un video di una persona che parla e una traccia audio diversa da quella originale, modificare la regione della bocca perché sia coerente con il nuovo audio, e lasciare invariato tutto il resto.




Difficoltà del lip sync

- **L'occhio rileva un audio in anticipo sulle labbra già di poche decine di millisecondi**, cioè dell'ordine della durata di un frame.
- **Chi ascolta guarda la bocca**, che è proprio la regione riscritta dal modello: ogni artefatto cade dove l'attenzione è concentrata.
- **L'identità dipende da dettagli piccoli**. Una modifica alla forma del mento o dei denti fa sembrare la persona un'altra.

L'errore fra i frame generati e quelli originali non misura nessuna di queste difficoltà.

L'esperto di sincronia come discriminatore




- Il generatore di **Wav2Lip** è addestrato con il giudizio di due reti, dette **discriminatori**: una giudica se l'immagine è verosimile, l'altra, l'**esperto di sincronia**, se le labbra corrispondono all'audio.
- L'esperto di sincronia, invece, è addestrato prima, su video reali, e durante l'addestramento del generatore resta **fisso**: fornisce un segnale che il solo confronto frame per frame non dà.
- Il discriminatore di qualità forma con il generatore una **GAN** (generative adversarial network): i due sono addestrati insieme, il discriminatore a distinguere i frame veri da quelli generati, il generatore a produrre frame che il discriminatore non distingue.
- Senza l'esperto di sincronia il generatore produce immagini verosimili e labbra che non seguono l'audio.



Evoluzione dei modelli per il lip sync


PERIODO	FAMIGLIA	CHE COSA HA AGGIUNTO	GENERAZIONE
2020	GAN	sincronia affidabile su un volto qualsiasi, ma a bassa risoluzione	una passata della rete
2024–2025	diffusione	dettaglio di labbra e denti, risoluzione più alta	decine di passate della rete

GAN: generatore e discriminatore



- Generatore e discriminatore sono addestrati **a turno**: il discriminatore a distinguere le immagini vere da quelle generate, il generatore a produrre immagini che il discriminatore classifica come vere.
- In una **GAN condizionata** il generatore riceve, oltre al rumore o al suo posto, un **condizionamento**, cioè un'informazione che guida il risultato: nel lip sync, l'audio e la regione della bocca da riscrivere.
- La generazione richiede **una sola passata** del generatore. L'addestramento invece è instabile, e il generatore può ridursi a produrre poche varianti (**mode collapse**).

Modelli di diffusione



- L'addestramento aggiunge **rumore** alle immagini vere, a livelli diversi, e la rete impara a stimare il rumore aggiunto.
- In generazione la stessa rete stima il rumore presente e ne toglie una parte a ogni passo.
- A ogni passo la rete riceve anche il **condizionamento**: per un'immagine un testo, nel lip sync l'audio e la regione della bocca da riscrivere.
- L'addestramento è **stabile**, a differenza di quello di una GAN; il prezzo è il **numero di passi**.



Generazione dell'intero volto parlante

- L'ingresso è **una sola immagine** e una traccia audio; l'uscita è un video di quella persona che parla, con pose della testa, battiti di ciglia ed espressioni.
- Il lip sync modifica una ripresa esistente, mentre qui **la ripresa non esiste**: pose ed espressioni sono generate e non corrispondono a niente che la persona abbia fatto.

La pipeline di doppiaggio




- Gli stadi sono modelli distinti, addestrati separatamente e su materiale diverso.
- Il testo intermedio permette di sostituire un modello per volta.

Allucinazioni del riconoscimento vocale

- Sui segmenti **senza parlato**, come le pause fra una frase e l'altra, un modello autoregressivo, come Whisper, può produrre frasi plausibili che nessuno ha pronunciato: ringraziamenti per la visione, inviti a visitare un sito.
- Dal solo testo è impossibile capire se il testo generato corrisponde a parole effettivamente pronunciate.
- Le contromisure **devono essere applicate prima della trascrizione**, e consistono nel togliere i segmenti senza parlato, individuati per esempio con una soglia sull'energia del segnale.

Propagazione dell'errore lungo la pipeline



- Vista l'indipendenza degli stadi della pipeline, nessun blocco è in grado, in principio, di rilevare errori avvenuti in blocchi precedenti.
- Ogni stadio aggiunge errori propri, perché riceve un ingresso diverso da quello su cui è stato addestrato.

L'errore è più semplice da riconoscere quando l'informazione è **simbolica (ovvero, normalmente, finché è testuale).**



PASSO 4

Valutazione: metriche automatiche e giudizio umano

Giudizio umano: MOS e confronto appaiato

Mean Opinion Score (MOS)

- più ascoltatori valutano ogni campione su una scala da uno a cinque, e i voti sono mediati: è lo standard de facto della letteratura
- poco sensibile: differenze reali fra sistemi vicini non emergono dai voti
- servono decine di ascoltatori per ottenere un intervallo di confidenza utile

Il MOS dipende dal gruppo di ascoltatori e dall'ordine di presentazione, quindi un MOS pubblicato e uno misurato in casa non sono confrontabili.

Confronto appaiato

- all'ascoltatore vengono presentati due campioni ed egli deve indicare il suo preferito
- più stabile, perché non richiede di ricordare una scala
- bastano molti meno ascoltatori per distinguere due sistemi vicini
- il risultato è una preferenza fra due sistemi, e per confrontarne di più occorre una serie di confronti



Famiglie di metriche automatiche per la voce

PROPRIETÀ	METODO	DIFETTO
intelligibilità	un riconoscitore vocale trascrive l'audio sintetico, e la misura è il tasso di errore di parola rispetto al testo da leggere	il valore dipende dal riconoscitore usato
somiglianza al parlante	un modello di verifica del parlante rappresenta l'audio sintetico e il campione di riferimento, e la misura è il coseno fra le due rappresentazioni	confronta soprattutto il timbro, e poco il ritmo e l'intonazione
naturalezza	un predittore neurale addestrato a riprodurre il MOS dato dagli ascoltatori	è affidabile solo su audio simile a quello su cui è stato addestrato

La metrica da usare discende dalla proprietà che l'applicazione richiede: un annuncio automatico in stazione chiede intelligibilità, un doppiaggio con la voce originale chiede naturalezza e somiglianza.



Metriche per il lip sync

METRICA	DIREZIONE	CHE COSA MISURA	DIFETTO
PSNR	più alta è meglio	fedeltà del frame rispetto all'originale	premia l'immobilità della bocca
FID	più bassa è meglio	verosimiglianza della distribuzione delle immagini	indifferente alla sincronia

Il FID è una metrica generica per la generazione di immagini, non specifica per il lip sync.

Metriche per la traduzione

- **BLEU** conta la sovrapposizione di sequenze di parole con una traduzione di riferimento, e correla male con il giudizio umano.
- **COMET** usa un encoder multilingue che proietta il testo in qualsiasi lingua che supporta in uno stesso spazio latente. Correla molto meglio con il giudizio umano, al prezzo di essere a sua volta un modello addestrato.
- **COMET-KIWI** produce una stima **senza traduzione di riferimento**, ed è la variante che serve nel doppiaggio, dove un riferimento non esiste quasi mai.



Valutazione della pipeline complessiva

- Ogni componente ha la sua metrica, e nessuna di loro quantifica l'accettabilità del video finale.
- La misura importante è **su esempi completi e lunghi**, prodotti dalla pipeline complessiva nelle condizioni in cui verrà usata: identità e coerenza del volto tendono a degradarsi con la durata.
- Accanto alla misura occorre un elenco di failure mode da cercare esplicitamente, perché nessuna metrica li rileva: la frase inventata dal riconoscimento, il nome proprio tradotto, la bocca che si muove durante un silenzio, il volto che salta a un cambio di inquadratura.
- L'elenco nasce dai failure mode osservati, e cresce con l'uso del sistema.



PASSO 5

Produzione e vincoli legali


Real-time factor e latenza iniziale

Il **real-time factor** è il tempo di calcolo diviso la durata dell'audio prodotto. La **latenza iniziale** è l'attesa fra la richiesta e l'inizio del suono.

- un real-time factor minore di 1 significa che il sistema produce l'audio più in fretta di quanto l'audio duri
- sulla stessa GPU, un modello leggero con un parlante fissato sta intorno a **0,04**, un modello di voice cloning zero-shot intorno a **0,3**
- i sistemi in streaming, che mandano in riproduzione l'audio mentre generano il resto, arrivano a **un centinaio di millisecondi** di latenza iniziale

Quanta attesa è ammessa dipende dall'applicazione, e il modello è scelto dopo, entro quel limite.

Detection della voce sintetica e filigrana



- Un detector impara **gli artefatti dei generatori che ha visto**, e quegli artefatti cambiano con l'architettura. Fuori dalla raccolta di addestramento cambiano anche le condizioni di registrazione.
- Nuovi generatori escono di continuo, e un detector in uso incontra **generatori che non ha mai visto**.
- La **filigrana** è un marchio impercettibile che chi genera inserisce nel segnale: dichiara la provenienza di un contenuto prodotto in buona fede, ma alcune ricodifiche del segnale la rimuovono senza un peggioramento udibile.

Una voce riconoscibile **non prova più l'identità** di chi parla, e la detection automatica non basta a riconoscere una voce falsa.

Articolo 50: marcatura e dichiarazione

- Dal **2 agosto 2026**, i **provider** di sistemi che generano audio, immagini, video o testo sintetici devono marcare l'uscita in **formato leggibile dalla macchina** e renderla rilevabile come generata artificialmente. Per i sistemi già sul mercato prima di quella data il termine è il **2 dicembre 2026**.
- Dal 2 agosto 2026, i **deployer**, cioè chi usa il sistema in un'attività professionale, devono **dichiarare** che un **deep fake** è stato generato o manipolato artificialmente.
- Un deep fake è un'immagine o un contenuto audio o video che somiglia a persone, luoghi o eventi esistenti e che sembrerebbe falsamente autentico. Per un'opera manifestamente artistica, satirica o di finzione la dichiarazione resta, in una forma che non disturba la visione.
- La marcatura è tecnica e la dichiarazione è rivolta a chi guarda: soddisfare l'una non soddisfa l'altra.

In una pipeline di doppiaggio la marcatura tocca al provider, che la costruisce, e la dichiarazione al deployer, che la usa per produrre il video.

Pratiche vietate e consenso

- Il riconoscimento delle emozioni sul luogo di lavoro e negli istituti di istruzione a partire da dati biometrici è vietato dal 2 febbraio 2025, con eccezioni strette per finalità mediche e di sicurezza. **Le caratteristiche della voce rientrano nell'ambito.**
- Clonare la voce di una persona identificabile richiede, nella pratica, il suo **consenso**.
- Le norme in gioco sono più d'una: protezione dei dati personali, diritti della personalità nei singoli ordinamenti e leggi specifiche sulle repliche vocali generate.
- Un campione vocale raccolto per una finalità non è automaticamente utilizzabile per addestrare un modello che ne riproduce la voce.

Il consenso deve essere raccolto [prima](#) di produrre il materiale, perché dopo non è più recuperabile.